



Universidad de Oviedo

FACULTAD DE CIENCIAS

GRADO EN FÍSICA

TRABAJO DE FIN DE GRADO

**Redes convolucionales como reconstructor
alternativo en óptica adaptativa**

Estudio comparativo con métodos tradicionales

Autor:

Anxo Herrera Castro

Tutores:

Jesús Daniel Santos Rodríguez

Francisco García Riesgo

Oviedo, 28 de mayo de 2026

Índice general

Índice de Figuras	3
Índice de Siglas	4
1. Introducción	5
2. La Óptica Adaptativa	7
2.1. Turbulencia atmosférica	7
2.1.1. El modelo de Kolmogorov	8
2.1.2. Longitud de coherencia de Fried	10
2.2. Componentes de un sistema de óptica adaptativa	11
2.2.1. Estrellas guía	11
2.2.2. Sensores de frente de onda	15
2.2.3. Sistemas correctores de frente de onda	17
2.2.4. Sistemas de reconstrucción	19
2.3. Configuraciones de óptica adaptativa	23
2.3.1. <i>Single Conjugate Adaptive Optics</i>	25
2.3.2. <i>Ground Layer Adaptive Optics</i>	25
2.4. Óptica adaptativa solar	25
2.4.1. El sensor de Shack-Hartmann de correlación	27
2.5. Simulador DASP	29
3. Fundamentos de Inteligencia Artificial	31
3.1. Redes neuronales artificiales	31
3.1.1. La neurona como unidad básica	31
3.1.2. El perceptrón multicapa	33
3.1.3. El teorema de aproximación universal	34

3.2. Entrenamiento de una red neuronal	35
3.2.1. Funciones coste	35
3.2.2. Ajuste de modelos	36
3.3. Redes neuronales convolucionales	39
3.3.1. Capas convolucionales	40
3.3.2. <i>Stride, padding y pooling</i>	40
3.3.3. Estructura de una red convolucional	42
3.3.4. Redes completamente convolucionales	44
3.4. Estrategias de regularización	45
3.4.1. Dropout	45
3.4.2. Normalización por lotes	46
3.4.3. Parada temprana	47
3.4.4. Reducción de la tasa de aprendizaje en estancamiento	47
4. Metodología y Diseño Experimental	49
4.1. Entorno de simulación	49
4.2. Parametrización y generación del conjunto de datos	49
4.3. Estructuración de los datos	50
4.3.1. Configuración de los sensores	50
4.4. Planteamiento y descripción de los modelos	53
4.4.1. Enfoque paramétrico	53
4.4.2. Enfoque espacial	59
5. Resultados y Discusión	64
5.1. Enfoque paramétrico	64
5.1.1. Comparativa y selección de arquitecturas MLP	64
5.1.2. Entrenamiento extendido y desempeño frente al estimador LS	66
5.2. Enfoque espacial	68
5.2.1. Entrenamiento de la red FCN	68
5.2.2. Comparativa con el método de LS	69
5.3. Comparación entre enfoques	70
6. Conclusiones y Trabajo Futuro	72
6.1. Conclusiones	72
6.2. Líneas de trabajo futuro	73
Bibliografía	74

Índice de figuras

1.1. Mejora de la resolución espacial mediante Óptica Adaptativa.	5
2.1. Esquema geométrico del tensor de estructura de Kolmogorov.	8
2.2. Esquema de componentes de un sistema de OA en lazo cerrado.	12
2.3. Aproximación de onda plana para estrellas guía	13
2.4. Principio de funcionamiento del sensor de frente de onda Shack-Hartmann.	16
2.5. Tipos de espejos deformables según su topología	18
2.6. Visualización de los polinomios de Zernike y sus aberraciones asociadas.	21
2.7. Comparativa entre configuraciones SCAO y GLAO	26
2.8. Comparativa de un SHWFS en observación nocturna frente a solar.	27
2.9. Detección de pendientes locales mediante correlación cruzada.	28
3.1. Comparación entre una neurona biológica y una neurona artificial	32
3.2. Comparativa entre funciones de activación más utilizadas	33
3.3. Esquema de un perceptrón multicapa con dos capas ocultas	34
3.4. Ejemplo de una convolución 2D	41
3.5. Comparación visual del efecto del <i>stride</i> en la convolución.	42
3.6. Ejemplo de arquitectura de una red CNN	43
3.7. Arquitectura de una red completamente convolucional	44
3.8. Representación del funcionamiento del <i>dropout</i>	46
3.9. Efecto de la parada temprana en las curvas de entrenamiento y validación.	48
4.1. Imágenes CCD simuladas para el arreglo de 7 sensores.	51
4.2. Esquema ilustrativo de la arquitectura convolucional	60
5.1. Curvas de aprendizaje para la comparativa de arquitecturas MLP.	65
5.2. Curvas de aprendizaje de las arquitecturas <i>wider</i> y ELU	68
5.3. Curva de entrenamiento de la red FCN	70

Índice de siglas

Adam	Adaptive Moment Estimation	MCAO	Multi Conjugate Adaptive Optics
ANN	Artificial Neural Network	MLP	Multi Layer Perceptron
CCD	Charge-Coupled Device	MOAO	Multi Object Adaptive Optics
CNN	Convolutional Neural Network	MSE	Mean Squared Error
DASP	Durham Adaptive Optics Simulation Platform	NGS	Natural Guide Star
DM	Deformable Mirror	OA	Óptica Adaptativa
ELU	Exponential Linear Unit	ReLU	Rectified Linear Unit
ELT	Extremely Large Telescope	RMS	Root Mean Square
FCN	Fully Convolutional Network	RMSE	Root Mean Squared Error
GELU	Gaussian Error Linear Unit	SCAO	Single Conjugate Adaptive Optics
GLAO	Ground Layer Adaptive Optics	SGD	Stochastic Gradient Descent
LGS	Laser Guide Star	SHWFS	Shack-Hartmann Wavefront Sensor
LR	Learning Rate	WFS	Wavefront Sensor
LS	Least Squares	XAO	Extreme Adaptive Optics
LTAO	Laser Tomography Adaptive Optics		
MAE	Mean Absolute Error		

1. Introducción

La luz emitida por los cuerpos celestes se desplaza inalterada por el espacio interestelar hasta llegar a la Tierra. A lo largo de este camino, la luz puede experimentar perturbaciones; sin embargo, estas no son comparables en magnitud con las sufridas en los últimos instantes al atravesar nuestra atmósfera antes de alcanzar los observatorios terrestres.

Este fenómeno tiene su origen en la naturaleza turbulenta de la atmósfera. Las variaciones locales de temperatura generan fluctuaciones en la densidad del aire y, en consecuencia, en su índice de refracción. Estos pequeños cambios en el índice de refracción actúan como pequeñas «lentes» que focalizan y distorsionan el frente de onda incidente. El resultado de este proceso se manifiesta en efectos como el centelleo (*twinkling*) y el ensanchamiento de la imagen estelar (*spreading*).




Figura 1.1 Mejora de la resolución espacial mediante óptica adaptativa. La imagen a la izquierda está dominada por la turbulencia atmosférica. La imagen de la derecha muestra claramente la estrella binaria. Imagen tomada de [1].

Esta barrera no es un descubrimiento reciente. En su obra *Opticks* (1704), Newton ya advirtió que la atmósfera imponía un límite fundamental a la resolución de los telescopios, insuperable mediante una mejora de las lentes [2]. Esa limitación condicionó la astronomía de alta resolución durante siglos, hasta que en las últimas décadas la Óptica Adaptativa (OA) ha permitido medir y corregir las deformaciones del frente de onda en tiempo real, acercando los telescopios terrestres a su resolución teórica.

Este Trabajo de Fin de Grado se centra en la óptica adaptativa de capa límite (GLAO) sobre fuentes extendidas de granulación solar. El objetivo principal es evaluar la viabilidad de sustituir los reconstructores clásicos, basados en el método de mínimos cuadrados, por modelos de aprendizaje automático. En particular, se aborda el diseño y entrenamiento de redes neuronales, incluyendo perceptrones multicapa y redes completamente convolucionales, para la reconstrucción del frente de onda a partir de las medidas del sensor.

2. La Óptica Adaptativa

2.1. Turbulencia atmosférica

La turbulencia atmosférica se describe como el conjunto de variaciones aleatorias en la velocidad de un fluido viscoso como la atmósfera. Los flujos no turbulentos son llamados **flujos laminares**. La distinción entre ambos regímenes se caracteriza a través del número de Reynolds [3]:

$$\text{Re} = \frac{v \cdot L}{\nu}, \quad (2.1)$$

donde v es la velocidad característica del flujo, L es la dimensión característica del obstáculo o dominio, y ν es la viscosidad cinemática del aire. Mientras que en sistemas cerrados (como conductos cilíndricos) la turbulencia se desarrolla a partir de $\text{Re} \approx 4000$ [3], en flujos atmosféricos abiertos la escala espacial es significativamente mayor, operando habitualmente en regímenes con $\text{Re} > 10^5$ [4], lo que los hace de naturaleza altamente turbulenta.

Para la caracterización de las turbulencias existen dos parámetros principales: la **escala interna** l_0 y la **escala externa** L_0 . Las turbulencias se generan en la escala externa, donde la energía cinética entra al sistema a través de fuentes macroscópicas. Los remolinos grandes se vuelven inestables, transformándose en remolinos más pequeños y transmitiéndoles toda su energía. Este proceso es conocido como **cascada de energía** y continúa hasta la escala interna. Para valores inferiores a l_0 , la energía interna se disipa en forma de calor [5].

2.1.1. El modelo de Kolmogorov

Para representar la turbulencia atmosférica, este trabajo emplea el **modelo de Kolmogorov**. Se trata de uno de los modelos más empleados porque permite representar el fenómeno a través de parámetros de sencilla medición, como la temperatura o la velocidad del viento.

Dado un punto de referencia arbitrario $\mathbf{r}_1$, Kolmogorov examinó el valor esperado del producto de las diferencias de velocidad respecto a un segundo punto separado por un vector de desplazamiento $\mathbf{r}$ (ver Figura 2.1). El tensor de estructura de la velocidad, D_{ij} , se define como [6]:

$$D_{ij}(\mathbf{r}_1, \mathbf{r}) = \langle [v_i(\mathbf{r}_1 + \mathbf{r}) - v_i(\mathbf{r}_1)][v_j(\mathbf{r}_1 + \mathbf{r}) - v_j(\mathbf{r}_1)] \rangle, \quad (2.2)$$

donde v_i, v_j son las componentes de la velocidad.




Figura 2.1 Representación espacial de las variables empleadas en el tensor de estructura de Kolmogorov. Un punto de evaluación se sitúa a una distancia y dirección dadas por el vector de desplazamiento $\mathbf{r}$ respecto a un punto de referencia $\mathbf{r}_1$. Los términos en rojo indican las velocidades locales en cada posición, cuya diferencia es evaluada estadísticamente por el tensor.

Cuando se emplea el modelo de Kolmogorov en observaciones reales, se trabaja en el denominado **rango inercial**. Físicamente, se dice que trabajamos en este rango cuando las escalas espaciales de las fluctuaciones se encuentran estrictamente delimitadas por la escala interna y la escala externa. Matemáticamente:

$$l_0 \ll r \ll L_0. \quad (2.3)$$

Operar dentro del rango inercial permite asumir tres simplificaciones críticas sobre el

fluido:

1. La atmósfera es localmente homogénea (la velocidad depende del vector $\mathbf{r}$).
2. La atmósfera es localmente isótropa (la velocidad depende solamente de la magnitud de $\mathbf{r}$).
3. La turbulencia es incompresible ($\nabla \cdot \mathbf{v} = 0$).

Estas asunciones dan lugar a la conocida ley de los 2/3 para la función de estructura de la velocidad [7]:

$$D_v = C_v^2 r^{2/3}, \quad (2.4)$$

donde C_v^2 es la constante de estructura de la velocidad, que cuantifica la energía de la turbulencia. En el contexto astronómico, las fluctuaciones de velocidad mezclan continuamente masas de aire con diferentes temperaturas. Estas variaciones térmicas producen cambios locales en la densidad del aire que, según la relación de Gladstone-Dale [8], se traducen en fluctuaciones del índice de refracción. Basándose en esto, Tatarskii [5] y Corrsin [9] extendieron la ley de los 2/3 de Kolmogorov al índice de refracción n , estableciendo la función de estructura fundamental para la óptica atmosférica:

$$D_n(r) = C_n^2 r^{2/3}, \quad l_0 < r < L_0, \quad (2.5)$$

donde C_n^2 es la constante de estructura del índice de refracción, con un significado similar a la constante de estructura de la velocidad.

Se puede asumir que la atmósfera está formada por un índice de refracción medio $\langle n(r) \rangle$ y una parte de fluctuación $n_1(r)$. La covarianza en el índice de refracción se obtiene como [7]:

$$B_n = \langle n_1(\mathbf{r} + \mathbf{r}_1) n_1(\mathbf{r}_1) \rangle, \quad (2.6)$$

y la densidad de potencia espectral se define como la transformada de Fourier de la covarianza [7]:

$$\Phi_n(\mathbf{K}) = \frac{1}{(2\pi)^3} \int d^3r B_n(\mathbf{r}) e^{-i\mathbf{K} \cdot \mathbf{r}} = \frac{5}{18\pi} C_n^2 K^{-3} \int_{l_0}^{L_0} dr \sin(Kr) r^{-1/3}. \quad (2.7)$$

Podemos aproximar la integral tomando $l_0 \rightarrow 0$, $L_0 \rightarrow \infty$ obteniendo el **espectro de Kolmogorov** [7]:

$$\Phi_n(K) = 0,033 C_n^2 K^{-11/3}. \quad (2.8)$$

Si no se toma una escala interna de valor cero, se obtiene el **espectro de Tatarskii**, que es útil para escalas internas finitas [5]:

$$\Phi_n(K) = 0,033C_n^2 K^{-11/3} \exp\left(-\frac{K^2}{(5,92/l_0)^2}\right). \quad (2.9)$$

Cuando la escala externa es finita, se obtiene el **espectro de von Kármán** [7]:

$$\Phi_n(K) = 0,033C_n^2 (K^2 + K_0^2)^{-11/6}. \quad (2.10)$$

La diferencia entre cada una de estas expresiones radica en las simplificaciones realizadas para determinar el valor de la Ecuación 2.7, y su validez se limita al rango inercial:

$$\frac{2\pi}{L_0} \leq K \leq \frac{2\pi}{l_0}. \quad (2.11)$$

A través de la función de densidad de potencia espectral se puede determinar la distribución de energía de la turbulencia conociendo su posición y su longitud de onda.

2.1.2. Longitud de coherencia de Fried

La **longitud de coherencia de Fried**, denotada r_0 , es el parámetro más importante del modelo de Kolmogorov, motivo por el que se ha decidido dedicarle un apartado. Físicamente, se puede definir como el diámetro máximo de la apertura de un telescopio antes de que la distorsión atmosférica limite su rendimiento. Un telescopio de diámetro D debería tener una resolución dada por el límite de difracción [7]:

$$\theta \approx 1,22\lambda/D. \quad (2.12)$$

Sin embargo, debido a la atmósfera, la resolución real queda limitada a:

$$\Delta\theta = 0,98 \frac{\lambda}{r_0}. \quad (2.13)$$

El parámetro de Fried puede ser determinado mediante la ecuación [10]:

$$r_0 = \left[0,423 k^2 \sec \beta \int_C C_n^2(h) dh \right]^{-3/5}, \quad (2.14)$$

donde β es el ángulo cenital y C es el camino óptico.

La longitud de coherencia de Fried permite, con un único valor numérico, caracterizar la intensidad de la turbulencia atmosférica en cada momento. En atmósferas muy turbulentas, el diámetro efectivo sobre el cual el frente de onda se mantiene plano es menor que en atmósferas en calma. En general, este parámetro toma valores entre 4 y 20 cm, siendo el caso de 20 cm el asociado a una situación nocturna ideal para la observación [11].

2.2. Componentes de un sistema de óptica adaptativa

En esta sección se describen los elementos que componen un sistema de óptica adaptativa tradicional, priorizando los modelos utilizados con mayor frecuencia.

El fundamento físico de la OA es el principio de **conjugación de fase** [1]. Un haz de luz distorsionado por la atmósfera, se describe matemáticamente por un campo eléctrico de la forma:

$$E(r,t) = E_0 e^{i(\mathbf{k} \cdot \mathbf{r} - \omega t - \phi)}, \quad (2.15)$$

siendo $\mathbf{k}$ el vector de propagación de la onda, $\mathbf{r}$ el vector de posición, E_0 la amplitud del campo y $\omega = 2\pi f$, donde f es la frecuencia de la onda. El término ϕ representa las aberraciones de fase introducidas por el medio turbulento.

El objetivo de la OA es revertir esta distorsión. Los sistemas de OA adaptan un componente llamado **espejo deformable** para crear un frente de onda con fase opuesta a la incidente (ver Figura 2.2). Matemáticamente, el sistema genera un campo con una fase conjugada [11]:

$$E(r,t) = E_0 e^{i(\mathbf{k} \cdot \mathbf{r} - \omega t + \phi)}. \quad (2.16)$$

Al superponer la corrección del espejo sobre el frente de onda distorsionado, los términos de fase se anulan entre sí, dando lugar a una onda plana libre de aberraciones.

2.2.1. Estrellas guía

Todos los sistemas de óptica adaptativa necesitan fuentes de referencia, denominadas estrellas guía, para medir las perturbaciones atmosféricas. Las estrellas **guía natura-**




Figura 2.2 Esquema de componentes de un sistema de óptica adaptativa en bucle cerrado. Se identifican los tres elementos principales del lazo de control: el espejo deformable (DM), que recibe la luz distorsionada por la atmósfera; el sensor de frente de onda (WFS) y el sistema de control en tiempo real (RTC), que procesa la señal y envía los comandos a los actuadores del espejo. El esquema incluye también elementos ópticos auxiliares como el divisor de haz, que redirige parte de la luz al sensor mientras el resto pasa a la cámara científica para formar la imagen corregida.

les (NGS, *Natural Guide Stars*) son objetos brillantes y compactos cercanos al objetivo científico. En observación nocturna, al tratarse de fuentes puntuales ubicadas a distancias astronómicas, sus frentes de onda incidentes se consideran ondas planas ideales (ver Figura 2.3), lo que permite estimar las aberraciones midiendo las distorsiones respecto a dicho plano [11].

Debido a la no-uniformidad de la atmósfera, si la estrella guía está demasiado lejos del objeto estudiado, las columnas de turbulencia que atraviesa la luz son distintas para cada uno. El ángulo isoplanático define la región angular dentro de la cual la turbulencia




Figura 2.3 Esquema de la propagación de la luz desde una estrella guía. Aunque la estrella emite frentes de onda esféricos, la inmensa distancia astronómica que la separa del telescopio hace que la curvatura de estos frentes disminuya progresivamente. Al alcanzar la apertura del instrumento, esta curvatura es tan insignificante que la luz incidente se asume como un frente de onda plano ideal.

atmosférica se considera invariante. Su magnitud viene dada por la expresión [7]:

$$\theta_0 = \left[2,91 k^2 \int_0^\infty C_n^2(z) z^{5/3} dz \right]^{-3/5}. \quad (2.17)$$

Este ángulo impone una limitación a las estrellas guía naturales, ya que exige la presencia de una estrella brillante dentro de un radio θ_0 alrededor del objeto de interés. Dado que esta condición de cobertura del cielo raramente se satisface en la práctica, surge la necesidad de generar **estrellas guía artificiales** (LGS, *Laser Guide Stars*).

El principio físico que permite la creación de estrellas artificiales es la **dispersión** o *scattering*. A nivel atómico, este proceso implica la aniquilación de un fotón incidente y la creación simultánea de un fotón dispersado.

Aunque existen numerosos mecanismos de interacción en medios gaseosos (como la dispersión de Mie o el efecto Raman inelástico), la generación de estrellas guía se basa en dos procesos que conservan la frecuencia de la radiación incidente: la **dispersión Rayleigh** en la atmósfera baja y la **dispersión por resonancia** en la capa de sodio mesosférica [11].

Dispersión Rayleigh

La dispersión Rayleigh ocurre cuando la luz incide sobre partículas cuyo tamaño es mucho menor que la longitud de onda de la radiación [12]. La eficiencia de este proceso viene dada por su **sección eficaz** σ , una magnitud que no es isotrópica, ya que depende del ángulo de observación y de la polarización de la luz.

En el contexto de las estrellas guía, la geometría de interés es la **retrodispersión** (un ángulo de dispersión $\theta = \pi$). En este límite, la sección eficaz escala según la relación $\sigma \propto \lambda^{-4}$ [11]. Esta dependencia matemática indica que el proceso es notablemente más efectivo para longitudes de onda cortas; el mismo mecanismo físico que explica el color azul del cielo.

El brillo de la estrella artificial es proporcional a la densidad atmosférica, que decae exponencialmente con la altura. Por ello, la utilización de estrellas guía Rayleigh está normalmente limitada a alturas moderadas, entre los 8 y los 12 km [13].

Resonancia en los átomos de sodio

A diferencia de la dispersión Rayleigh, la generación de estrellas guía de sodio aprovecha una capa de átomos neutros de origen meteórico situados en la mesosfera. Esta capa abarca desde los 80 a los 110 km, con un pico de densidad centrado a 92 km [14]. A esta altitud, la dispersión de Rayleigh es despreciable. Sin embargo, la gran sección eficaz de la resonancia del sodio permite generar un retorno brillante utilizable como referencia artificial.

Los átomos de sodio, inicialmente en su estado fundamental y equilibrio térmico (en torno a los 200 K) son excitados mediante un láser de 589 nm, sintonizado a la frecuencia de resonancia. Esto transfiere la población al estado excitado. El átomo decae naturalmente tras su vida media ($\tau \approx 16$ ns). Esta dispersión es incoherente e isotrópica. La componente de la radiación en la dirección del telescopio es la retrodispersión deseada que forma la estrella guía [7].

2.2.2. Sensores de frente de onda

Los sensores de frente de onda son uno de los elementos fundamentales de cualquier sistema de OA. En esta sección se introduce el principio físico por el que se rigen, así como el tipo de sensor más utilizado en la práctica: el sensor de Shack-Hartmann.

La fase del campo eléctrico no interactúa directamente con la materia de una forma que podamos medir. Todos los detectores ópticos (CCD's, fotodiodos) solo son capaces de medir la intensidad, la cual es proporcional al cuadrado de la magnitud del campo eléctrico $I \propto |E|^2$ [15].

A través del principio de **Huygens-Fresnel**, se puede deducir la integral de difracción de Fraunhofer [1]:

$$I(x,y) = \left| \frac{1}{i\lambda f} \iint_{-\infty}^{\infty} \underbrace{A(\xi,\eta)e^{i\phi(\xi,\eta)}}_{\text{Campo en Pupila}} \cdot \exp \left[-i\frac{k}{f}(x\xi + y\eta) \right] d\xi d\eta \right|^2 \quad (2.18)$$

que relaciona la intensidad focalizada con la transformada de Fourier del campo. Pero esta función **no es invertible**. Para un patrón de intensidad dado, existen muchas fases del campo eléctrico compatibles con él. De esta forma, es imposible recuperar la fase conociendo únicamente el patrón de intensidad.

Sensor de Shack-Hartmann

El sensor de Shack-Hartmann, también llamado SHWFS por sus siglas en inglés *Shack-Hartmann Wavefront Sensor*, es uno de los sensores de frente de onda más utilizados en OA. Este sensor está basado en el **test de Hartmann**, un test de metrología óptica desarrollado por Johannes Hartmann en 1900 para evaluar la calidad óptica de imágenes astronómicas [16].

El test consiste en colocar una máscara opaca con una colección de aperturas que discretizan el rayo incidente. La máscara selecciona haces individuales que se proyectan en un plano de detección. La medida consiste en comparar la posición real de los impactos luminosos con su posición teórica ideal. El problema principal de este test era la baja eficiencia, pues la máscara opaca bloquea la mayor parte de la luz incidente. Platt y Shack propusieron una modificación a principios de la década de 1970, sustituyendo

los orificios por una matriz de microlentes [17]. Esta configuración permite aprovechar prácticamente la totalidad del flujo luminoso incidente.

El sensor de frente de onda de Shack-Hartmann está formado por una matriz de lentes separada de un sensor de fotones CCD por una distancia f (ver Figura 2.4). Cuando el frente de onda está aberrado, la luz no se proyecta sobre los centros de la matriz CCD, sino sobre posiciones desplazadas proporcionalmente a la aberración local. El desplazamiento de la imagen respecto del punto es proporcional a la pendiente del frente de onda en cada lente.




Figura 2.4 Representación gráfica del funcionamiento del sensor Shack-Hartmann. Los puntos perfectamente distribuidos se corresponden con la proyección de un frente de onda plano. Cuando el frente de onda está aberrado, se produce un desplazamiento respecto al equilibrio. Este desplazamiento es clave en la reconstrucción de la fase global de la radiación incidente. Imagen tomada de [18].

La posición media de los fotones que inciden sobre una subapertura específica se denomina **centroide**. Matemáticamente, es el primer momento de la distribución de irradiancia [19]:

$$x_c = \frac{\iint x \cdot I(x,y) \, dx \, dy}{\iint I(x,y) \, dx \, dy}, \quad y_c = \frac{\iint y \cdot I(x,y) \, dx \, dy}{\iint I(x,y) \, dx \, dy}. \quad (2.19)$$

Dado que los sensores son matrices de píxeles discretos, la integral se sustituye por el sumatorio asociado a cada subapertura k . Si I_{ij} es la intensidad medida en el píxel (x_i, y_j) , entonces:

$$x_{c,k} = \frac{\sum_{i,j} x_i \cdot I_{i,j}}{\sum_{i,j} I_{i,j}}, \quad y_{c,k} = \frac{\sum_{i,j} y_j \cdot I_{i,j}}{\sum_{i,j} I_{i,j}}. \quad (2.20)$$

El centroide por sí solo carece de interés. En OA se compara su valor con el de una posición de referencia calculada (x_r, y_r) , habitualmente obtenido a través de estrellas guía naturales o artificiales. Con esta información se puede estimar la pendiente del

frente de onda $\nabla\varphi$ como:

$$s_{x,k} = \left. \frac{\partial\varphi}{\partial x} \right|_k \approx \frac{x_{c,k} - x_{ref,k}}{f_{ml}}, \quad s_{y,k} = \left. \frac{\partial\varphi}{\partial y} \right|_k \approx \frac{y_{c,k} - y_{ref,k}}{f_{ml}}. \quad (2.21)$$

2.2.3. Sistemas correctores de frente de onda

Una vez el frente de onda es conocido, es necesario tener un sistema para corregirlo aplicando el método de conjugación de fase. Esta corrección se lleva a cabo mediante sistemas correctores de fase. Estos se clasifican en dos categorías principales: espejos tilt (de inclinación) y espejos deformables (DM, *Deformable Mirrors*). Estos componentes actúan secuencialmente: los espejos tilt eliminan aberraciones de bajo orden (*tip* y *tilt*), mientras que las aberraciones de orden superior son eliminadas por los DM.

Espejos tilt

Su tarea fundamental es corregir la inclinación global del frente de onda, asegurando que la imagen esté centrada en el sensor. Su superficie es rígida, pues el espejo solo cambia su inclinación.

El modelo de Kolmogorov permite deducir la desviación típica de la inclinación producida por la atmósfera [7]:

$$\sigma_{tilt} = 0,43 \cdot \left(\frac{D}{r_0} \right)^{5/6} \frac{\lambda}{D}, \quad (2.22)$$

donde D es la apertura del telescopio. Para asegurar que el espejo sea capaz de eliminar la mayoría de los eventos de turbulencia, se impone que la máxima cantidad de inclinación de este sea $M_{tilt} = \pm 2,5\sigma_{tilt}$.

La inclinación no se elimina moviendo el espejo principal de mayor tamaño, sino utilizando un espejo más pequeño que puede desplazarse más rápidamente. Teniendo en cuenta un factor de 1/2 debido a la reflexión, el ángulo total (o *stroke*) que se debe poder desplazar un espejo tilt debe ser al menos:

$$\text{Stroke} = \frac{1}{2} M_{tilt} \left(\frac{D_{\text{telescopio}}}{D_{\text{espejo}}} \right) \quad (2.23)$$

Espejos deformables

La misión de los espejos deformables es corregir aberraciones de alto orden— como el desenfoque o el astigmatismo—, que deja el espejo tilt. A diferencia de este, su superficie no es rígida, sino que se modifica en tiempo real para cancelar las deformaciones de fase introducidas por la atmósfera.

Se distinguen dos arquitecturas principales en base a la topología de la superficie del espejo:

- **Espejos segmentados.** Están formados por segmentos planos e individuales que son desplazados por pistones (ver Figura 2.5.a).
- **Espejos de superficie continua.** Están constituidos por una lámina delgada y flexible que actúa como espejo. A diferencia de los segmentados, la deformación es suave y continua (ver Figura 2.5.b).




Figura 2.5 Dos arquitecturas diferentes para espejos deformables. Los espejos segmentados están formados por una colección de planos individuales, mientras que los espejos de superficie continua están constituidos por lámina delgada y flexible. Imagen adaptada de [20].

La deformación se logra mediante una matriz de actuadores que empujan y tiran localmente de la superficie del espejo. El tipo más común de actuadores está basado en el **efecto piezoeléctrico inverso**, el cual induce una deformación mecánica proporcional a un campo eléctrico aplicado. Materiales como el titanato zirconato de plomo

muestran un efecto piezoeléctrico fuerte. Por otro lado, los materiales **magnetostrictivos** generan un desplazamiento como respuesta a un campo magnético. El Terfenol es un ejemplo de material con esta propiedad [7].

Pese a tratarse de otro de los elementos fundamentales en cualquier sistema de OA, los espejos deformables no serán de aplicación para este trabajo. Para que su aplicación sea óptima, es necesario reconstruir y conocer la turbulencia atmosférica en cada momento para que puedan adquirir la forma que elimine el máximo de aberraciones del frente de onda incidente. El objetivo de este trabajo será ese, buscar nuevos métodos de reconstrucción para caracterizar mejor la turbulencia y, de este modo, optimizar el funcionamiento tanto de este tipo de espejos como de todo el sistema de OA en general.

2.2.4. Sistemas de reconstrucción

Estos sistemas son los responsables de determinar la corrección óptima para compensar un frente de onda aberrado. Constituyen el núcleo de esta investigación, cuyo objetivo principal es el desarrollo de reconstructores basados en redes neuronales artificiales (ANN, *Artificial Neural Networks*). En esta sección, se discutirán los algoritmos matriciales clásicos utilizados como referencia.

En la teoría de control de la óptica adaptativa, las estrategias de reconstrucción se clasifican atendiendo a dos dimensiones operativas fundamentales [11]:

1. **Base espacial.** Los métodos **zonales** abordan la reconstrucción de forma discreta y local, evaluando la fase o el comando directamente en la posición de cada subapertura o actuador. Por el contrario, los métodos **modales** describen el frente de onda globalmente como una combinación lineal de funciones base continuas y ortogonales.
2. **Estrategia de control.** Los métodos **directos** calculan una representación explícita de la fase como paso intermedio antes de determinar los comandos del espejo deformable. Los métodos **indirectos** omiten este paso, mapeando geométricamente las pendientes medidas por el sensor directamente a los voltajes de los actuadores.

Las arquitecturas de reconstrucción basadas en ANN en las que se fundamenta este trabajo incluyen una aproximación modal y otra zonal.

Por un lado, la arquitectura basada en perceptrones multicapa (MLP, *Multi-Layer Perceptron*) implementa una **reconstrucción modal directa**, en la que se estiman los coeficientes de una base de Zernike que describen globalmente el frente de onda. A partir de esta representación modal, se derivan posteriormente los comandos del espejo deformable.

Por otro lado, la arquitectura basada en redes neuronales completamente convolucionales (FCN, *Fully Convolutional Networks*) sigue un enfoque **zonal**, aprendiendo un mapeo directo desde las medidas del sensor a la salida deseada mediante operaciones locales sobre la estructura espacial de los datos. En este caso, no se emplea una base modal explícita, sino una representación implícita.

Polinomios de Zernike

Los polinomios de Zernike son las funciones utilizadas para representar las aberraciones atmosféricas de forma modal. Debido a la simetría circular de las aperturas de los telescopios, esta base de polinomios es idónea por ser ortogonal sobre el círculo unitario. La expansión general del frente de onda se expresa como [7]:

$$\begin{aligned} \varphi(r, \theta) = & A_{00} + \frac{1}{\sqrt{2}} \sum_{n=2}^{\infty} A_{n0} R_n^0 \left(\frac{r}{R'} \right) \\ & + \sum_{n=1}^{\infty} \sum_{\substack{m=1 \\ (n-m) \text{ par}}}^n R_n^m \left(\frac{r}{R'} \right) [A_{nm} \cos(m\theta) + B_{nm} \sin(m\theta)], \end{aligned} \quad (2.24)$$

donde R' es el radio del círculo sobre el que se definen los polinomios y donde la parte radial se escribe [7]:

$$R_n^m \left(\frac{r}{R'} \right) = \sum_{s=0}^{(n-m)/2} \frac{(-1)^s (n-s)!}{s! \left(\frac{n+m}{2} - s \right)! \left(\frac{n-m}{2} - s \right)!} \left(\frac{r}{R'} \right)^{n-2s}. \quad (2.25)$$

La Figura 2.6 representa gráficamente los primeros polinomios de Zernike con sus aberraciones correspondientes.

La información recogida por el SHWFS es utilizada para reconstruir la fase del frente




Figura 2.6 Visualización de los polinomios de Zernike de primeros órdenes y sus aberraciones correspondientes.

de onda. Para ello, la fase se describe por una expansión en M modos [7]:

$$\Phi(r, \varphi) = \sum_{j=1}^M a_j Z_j(r, \varphi). \quad (2.26)$$

Las pendientes medidas por el SHWFS se relacionan con los polinomios de Zernike a través de las ecuaciones [7]:

$$s_{x,k} = \sum_{n=1}^M a_n \left. \frac{\partial Z_n(x,y)}{\partial x} \right|_k, \quad s_{y,k} = \sum_{n=1}^M a_n \left. \frac{\partial Z_n(x,y)}{\partial y} \right|_k, \quad (2.27)$$

dando lugar a un sistema lineal de la forma $\mathbf{s} = \mathbf{B}\mathbf{a}$, con:

$$\mathbf{s} = \begin{bmatrix} s_{x,1} & \cdots & s_{x,N}, & s_{y,1} & \cdots & s_{y,N} \end{bmatrix}^T, \quad \mathbf{a} = \begin{bmatrix} a_1 & a_2 & \cdots & a_M \end{bmatrix}^T \quad (2.28)$$

mientras que la matriz $\mathbf{B}$, de dimensiones $2N \times M$, se define como:

$$\mathbf{B} = \begin{bmatrix} \left. \frac{\partial Z_1}{\partial x} \right|_1 & \left. \frac{\partial Z_2}{\partial x} \right|_1 & \cdots & \left. \frac{\partial Z_M}{\partial x} \right|_1 \\ \vdots & \vdots & \ddots & \vdots \\ \left. \frac{\partial Z_1}{\partial x} \right|_N & \left. \frac{\partial Z_2}{\partial x} \right|_N & \cdots & \left. \frac{\partial Z_M}{\partial x} \right|_N \\ \left. \frac{\partial Z_1}{\partial y} \right|_1 & \left. \frac{\partial Z_2}{\partial y} \right|_1 & \cdots & \left. \frac{\partial Z_M}{\partial y} \right|_1 \\ \vdots & \vdots & \ddots & \vdots \\ \left. \frac{\partial Z_1}{\partial y} \right|_N & \left. \frac{\partial Z_2}{\partial y} \right|_N & \cdots & \left. \frac{\partial Z_M}{\partial y} \right|_N \end{bmatrix}. \quad (2.29)$$

El problema consiste en obtener el vector de coeficientes $\mathbf{a}$. Sin embargo, la matriz $\mathbf{B}$ es generalmente rectangular y, por la naturaleza de las medidas, el sistema suele estar **mal condicionado**. Por tanto, es habitual no poder obtener una inversión matricial directa. El método de **mínimos cuadrados** (LS, *Least Squares*) es el procedimiento más utilizado para solucionar este problema.

Método de mínimos cuadrados

El método de mínimos cuadrados es el procedimiento clásico utilizado para el cálculo de los coeficientes de Zernike a partir de las medidas locales de las subaperturas. Este enfoque plantea un problema de optimización definiendo una función coste basada en la norma euclídea al cuadrado del error residual [7]:

$$J = \|\mathbf{s} - \mathbf{B}\hat{\mathbf{a}}\|_2^2 = [\mathbf{s} - \mathbf{B}\hat{\mathbf{a}}]^T [\mathbf{s} - \mathbf{B}\hat{\mathbf{a}}], \quad (2.30)$$

donde $\hat{\mathbf{a}}$ es tal que $\frac{\partial J}{\partial \hat{\mathbf{a}}} = 0$. Resolviendo esta condición, la estimación del vector de coeficientes $\mathbf{a}$ se obtiene directamente como:

$$\hat{\mathbf{a}} = \underbrace{(\mathbf{B}^T \mathbf{B})^{-1} \mathbf{B}^T}_{\mathbf{B}^\dagger} \mathbf{s}. \quad (2.31)$$

$\mathbf{B}^\dagger$ se conoce como la **pseudo-inversa** de $\mathbf{B}$. Del mismo modo que antes, la matriz $(\mathbf{B}^T \mathbf{B})$ puede no ser inversible o estar mal condicionada. Este problema se solventa utilizando la **descomposición en valores singulares**, en la que la matriz $\mathbf{B}$ se expresa como producto de tres matrices más simples:

$$\mathbf{B} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \quad (2.32)$$

donde $\mathbf{U}$ y $\mathbf{V}$ son matrices unitarias de dimensiones $2N \times 2N$ y $M \times M$, respectivamente; mientras que $\mathbf{\Sigma}$ es una matriz diagonal de dimensión $2N \times M$ que contiene los valores singulares σ_j ordenados decrecientemente. En la práctica, estas matrices se hallan por métodos computacionales [21].

El estimador de mínimos cuadrados, pese a su robustez, está condicionado por una complejidad de $\mathcal{O}(M \times M)$, lo que representa un cuello de botella crítico para la escala de los futuros telescopios gigantes, como el ELT (*Extremely Large Telescope*) [22]. Las arquitecturas basadas en ANN se proponen aquí como una vía para optimizar este balance computacional [19, 23]. El objetivo fundamental es trasladar el coste computacional a la fase de entrenamiento de la red. De este modo, se aceleran los tiempos de procesamiento durante la fase de inferencia y se mejora la precisión en la reconstrucción del frente de onda.

2.3. Configuraciones de óptica adaptativa

Los sistemas de OA se clasifican en función del número de componentes, su ubicación en el camino óptico y la estrategia de control implementada. Principalmente, se distinguen dos regímenes de operación [11]:

- Sistemas de **lazo abierto** (*open loop*). El sensor de frente de onda se sitúa ópticamente **antes** del espejo deformable. El sensor mide la turbulencia atmosférica total y el sistema de control calcula y envía los comandos al espejo. Sin embargo, el WFS no observa el haz corregido, por lo que el sistema ejecuta la orden a ciegas, sin verificar el resultado de su propia corrección.
- Sistemas de **lazo cerrado** (*closed loop*). El WFS se sitúa ópticamente **después** del DM. En esta configuración, el sensor no mide la turbulencia total, sino el error residual; es decir, la diferencia entre la aberración atmosférica y la corrección

aplicada por el DM en la iteración inmediatamente anterior. El sistema opera de forma continua para minimizar este error, exigiendo modificaciones de menor amplitud sobre los actuadores y facilitando un control mucho más estable en tiempo real.

Los sistemas de OA también se clasifican en función del número de estrellas guía, espejos deformables y la estrategia de reconstrucción empleada, dando lugar a las siguientes configuraciones principales [24]:

1. **SCAO** (*Single Conjugate Adaptive Optics*). Formado por un único WFS y un único DM. La corrección es óptima en una sola dirección, y el campo corregido es reducido.
2. **GLAO** (*Ground Layer Adaptive Optics*). Utiliza múltiples estrellas guía como referencia. Corrige principalmente la turbulencia de baja altitud (*ground layer*), proporcionando una mejora uniforme en un campo amplio.
3. **MCAO** (*Multi Conjugate Adaptive Optics*). Formado por varios WFS y varios DM conjugados a distintas alturas. La corrección de la turbulencia es tridimensional y en un campo amplio.
4. **LTAO** (*Laser Tomography Adaptive Optics*). Utiliza múltiples estrellas guía láser y sensores para reconstruir la turbulencia en tres dimensiones. La corrección se aplica mediante un único DM, optimizando la calidad de imagen en una sola dirección.
5. **MOAO** (*Multi Object Adaptive Optics*). Formado por múltiples WFS y varios DM asignados individualmente a cada objeto científico. Proporciona corrección local independiente para múltiples direcciones dentro de un campo amplio, operando habitualmente en lazo abierto.
6. **XAO** (*Extreme Adaptive Optics*). Formado por un gran número de actuadores operando a alta frecuencia. Proporciona un grado de corrección máximo en un campo muy reducido, siendo indispensable para observaciones de alto contraste.

En este trabajo nos centramos en las configuraciones **SCAO** y **GLAO**: la primera como caso base fundamental, y la segunda como escenario de aplicación principal.

2.3.1. *Single Conjugate Adaptive Optics*

El sistema SCAO es la arquitectura más simple en lazo cerrado. Su diseño se basa en el uso de una única estrella de referencia y un único espejo deformable conjugado al plano de la pupila del telescopio. El esquema de esta configuración se ilustra en la Figura 2.7.a.

Si bien SCAO ofrece muy buenos resultados en el eje óptico, su rendimiento está severamente limitado por el anisoplanatismo angular. Dado que el sistema proyecta la turbulencia volumétrica (3D) de la atmósfera en una única corrección plana (2D), la calidad de la fase corregida se degrada drásticamente para objetos situados más allá del ángulo isoplanático [23].

2.3.2. *Ground Layer Adaptive Optics*

El objetivo de la configuración GLAO es corregir la capa turbulenta más cercana a la superficie terrestre. La GLAO busca una corrección moderada en un campo muy amplio, a diferencia de la corrección puntual del SCAO [23].

Utiliza como información de entrada numerosas estrellas y mide la turbulencia con múltiples sensores. Esta configuración utiliza un único espejo deformable, al igual que la anterior (ver Figura 2.7.b).

En este trabajo se considera un sistema GLAO con siete WFS: seis distribuidos en anillo y uno en la dirección central.

2.4. Óptica adaptativa solar

En su diseño básico, los sistemas de OA solar son muy similares a los de OA nocturna. No obstante, estos sistemas se enfrentan a una serie de retos que los nocturnos no encuentran.

El primero de ellos es el intenso calentamiento diurno del suelo por la radiación solar directa, el cual induce una capa de turbulencia rasante mucho más severa. Esto provoca que el parámetro de Fried varíe dramáticamente en escalas de tiempo muy cortas




Figura 2.7 Comparación entre configuraciones SCAO (izquierda) y GLAO (derecha). El sistema SCAO cuenta con un único WFS y un único DM conjugado al plano de la pupila. Por otro lado, el sistema GLAO está formado por múltiples WFS distribuidos en el campo y un único DM para la corrección global.

(segundos), cayendo frecuentemente a valores de apenas unos pocos centímetros. Este comportamiento se diferencia de la mayor estabilidad temporal y en el infrarrojo característica de la observación nocturna [25].

En segundo lugar, la astronomía solar opera fundamentalmente en el espectro visible (alcanzando longitudes de onda de hasta 380 nm), mientras que la nocturna suele operar en el infrarrojo [25]. Reescribiendo la Ecuación 2.14 en función de λ se llega a:

$$r_0 = \left[0,423 k^2 \sec \beta \int_C C_n^2(h) dh \right]^{-3/5} \quad (2.33)$$

$$= \left[0,423 \cdot \frac{4\pi^2}{\lambda^2} \sec \beta \int_C C_n^2(h) dh \right]^{-3/5} \propto \lambda^{6/5}. \quad (2.34)$$

Es decir, r_0 crece con la longitud de onda. Esto implica que longitudes de onda más cortas generan un r_0 más pequeño. Por tanto, el frente de onda se mantiene coherente

en regiones más pequeñas de la pupila. Estas condiciones generan requerimientos espaciales mucho más estrictos, obligando a utilizar una altísima densidad de subaperturas y actuadores [25].

Por último, el sensor de frente de onda en un telescopio solar no dispone de fuentes luminosas puntuales sobre un fondo oscuro (estrellas), sino que debe inferir las aberraciones operando sobre objetos extendidos, de bajo contraste y variables en el tiempo, como la **granulación solar** (ver Figura 2.8).

Por todo ello, la OA supone un desafío mayor que la nocturna. Mientras que la tecnología para observaciones nocturnas ha alcanzado un alto grado de madurez, los algoritmos solares tradicionales operan al límite de la viabilidad del hardware. Este escenario justifica aún más la necesidad de nuevos métodos de reconstrucción basados en ANN.




Figura 2.8 Comparación de los patrones formados en el plano focal de un sensor de frente de onda Shack-Hartmann. (Izquierda) Patrón característico en Óptica Adaptativa nocturna: la matriz de microlentes enfoca la luz de una fuente puntual, generando una matriz de puntos discretos. (Derecha) Patrón correspondiente a la Óptica Adaptativa solar: al tratarse de una fuente extendida, las microlentes obtienen imágenes de bajo contraste y variables en el tiempo, como la granulación solar.

2.4.1. El sensor de Shack-Hartmann de correlación

En la OA nocturna, la imagen en cada subapertura del sensor es un punto (la estrella guía), su desplazamiento se determina calculando el centroide de la mancha de luz. Por otro lado, en la OA solar la imagen en cada subapertura es un patrón complejo de gránulos solares (ver Figura 2.8). Calcular el centroide de una superficie casi uniforme

carece de sentido. Por ello, el sensor de correlación de Shack-Hartmann calcula, en su lugar, la **correlación cruzada** con una imagen de referencia [25]:

$$CC(\Delta_i) = \sum \sum I_M(\mathbf{x}) \times I_R(\mathbf{x} + \Delta_i), \quad (2.35)$$

donde I_M es la imagen de la subapertura, I_R es la imagen de referencia y Δ_i es el desplazamiento en píxeles entre la imagen medida y la de referencia. Normalmente basta con calcular la correlación en una matriz de píxeles 5×5 .

Tras calcular la función de correlación cruzada, el sistema localiza su máximo global. La posición de este pico determina el desplazamiento relativo de la imagen en la subapertura, el cual es directamente proporcional a la pendiente local (*tilt*) del frente de onda.




Figura 2.9 Proceso de estimación de inclinaciones locales en el frente de onda solar. El sistema sustituye el cálculo de centroides de la OA nocturna por la localización del máximo de la correlación cruzada entre la granulación de la subapertura y una referencia. Imagen adaptada de [25].

Mediante un ajuste parabólico o aplicando un centroide, se refina la posición de este pico a nivel subpixel. Una vez calculados los desplazamientos para todas las subaperturas se determina el mapa de vectores de inclinación. Completada esta etapa, el procesamiento funciona igual que la OA nocturna [25]. Este procedimiento está sintetizado en la Figura 2.9.

La principal distinción respecto al sistema nocturno es el alto coste computacional añadido por el cálculo de las correlaciones.

2.5. Simulador DASP

Para la generación de datos de este trabajo se ha utilizado DASP (*Durham Adaptive Optics Simulation Platform*) [26, 27], un entorno de simulación desarrollado por la Universidad de Durham. Esta herramienta permite modelar de forma integral sistemas de óptica adaptativa, admitiendo variaciones en el número y tipo de estrellas guía, sensores de frente de onda y espejos deformables. Su flexibilidad permite reproducir tanto las condiciones nocturnas clásicas como configuraciones de óptica adaptativa solar.

La propagación óptica a través de la atmósfera turbulenta se modela mediante simulaciones de Montecarlo [26]. DASP genera las pantallas de fase siguiendo el espectro de von Kármán introducido en la Sección 2.1.1, con escala interna despreciable y con escala externa finita cuyo valor se especifica en la metodología. El sistema permite estratificar esta turbulencia en múltiples capas atmosféricas definidas por el usuario, asignando a cada una su propio perfil de intensidad, velocidad y dirección del viento.

La selección de DASP se basa en su capacidad para generar y registrar la telemetría completa del sistema de óptica adaptativa, lo que permite construir conjuntos de datos supervisados a través de simulación. En cada ejecución, DASP proporciona simultáneamente:

- **Entradas.** Datos del sensor Shack-Hartmann, incluyendo imágenes por subapertura y pendientes locales del frente de onda.
- **Objetivos.** Coeficientes de Zernike del frente de onda simulado y el mapa de fase asociados a la dirección central.

Esta correspondencia entrada–salida permite entrenar modelos de **aprendizaje supervisado**. Además, se registran las reconstrucciones obtenidas mediante el método clásico de LS, que se emplea como referencia para evaluar el rendimiento de las redes neuronales.

Cada simulación queda definida por un fichero de parámetros en el que se fijan las condiciones atmosféricas y del sistema (p.ej., r_0 , L_0).

3. Fundamentos de Inteligencia Artificial

3.1. Redes neuronales artificiales

3.1.1. La neurona como unidad básica

El estudio de las redes neuronales artificiales ha recibido una gran inspiración de los sistemas biológicos de aprendizaje. Estos sistemas están compuestos por redes complejas de neuronas interconectadas. Del mismo modo, las ANN están formadas por conjuntos densamente conectados de unidades más simples, que toman un conjunto de valores reales como entrada y devuelven un único valor real como salida (ver Figura 3.1). Matemáticamente, el comportamiento de una neurona individual se modela como una función escalar:

$$y = g\left(\sum_{i=1}^n w_i x_i + b\right) \quad (3.1)$$

donde x_i representa la **señal de entrada** (proveniente directamente de los datos observables o de las activaciones de una capa previa), w_i son los **pesos** sinápticos que ponderan la importancia de cada conexión entrante, y b es el **sesgo** (*bias*), un término independiente que desplaza el umbral de activación de la neurona.

Funciones de activación El papel de la función $g(\cdot)$ es indispensable. Su objetivo es introducir la no linealidad en el sistema; de lo contrario, el argumento

$$z = \sum_{i=1}^n w_i x_i + b \quad (3.2)$$




Figura 3.1 Comparación entre una neurona biológica y una neurona artificial. Esta función procesa las señales de las neuronas anteriores y devuelve un valor real. Imagen tomada de [28].

constituiría estrictamente una transformación afín. En ausencia de funciones de activación no lineales, cualquier red neuronal, independientemente del número de capas ocultas que posea, colapsaría en una única transformación lineal equivalente, incapacitando al modelo para representar funciones no lineales. Algunos ejemplos de funciones de activación son:

- **Sigmoide.** Se define como $\sigma(z) = \frac{1}{1+e^{-z}}$. Es una función diferenciable y mapea la salida al intervalo (0,1). Esto es de especial utilidad pues comprime los valores atípicos (*outliers*) dentro de un rango acotado.
- **Tangente hiperbólica.** Una función muy similar a la sigmoide utilizada con mayor frecuencia $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$. Su diferencia principal con la anterior es que toma valores entre -1 y 1.
- **ReLU (Rectified Linear Unit).** Definida como $\text{ReLU}(z) = \max(z, 0)$ tiene propiedades distintas de las anteriores debido a su similitud con una función lineal. Las funciones sigmoide y tanh tienen problemas de **saturación** pues valores muy elevados de $|z|$ son muy próximos a 1 y tienen derivada casi nula. Este problema se conoce como el **desvanecimiento del gradiente**.
- **ELU (Exponential Linear Unit).** Se trata de una variación de la activación ReLU que utiliza una curva exponencial para los valores negativos. Se define como:

$$\text{ELU}(z) = \begin{cases} z & \text{si } z \geq 0 \\ \beta(e^z - 1) & \text{si } z < 0 \end{cases}$$

donde β es un hiperparámetro constante. A diferencia de ReLU, ELU puede producir salidas negativas, lo que ayuda a empujar la media de las activaciones más cerca de cero y acelera la convergencia del aprendizaje.

- **GELU** (*Gaussian Error Linear Unit*). Esta función pondera las entradas no por su signo (como ReLU), sino por su magnitud, introduciendo una no linealidad estocástica. Se define como $\text{GELU}(z) = z \cdot \Phi(z)$, donde $\Phi(z)$ es la función de distribución acumulada de la distribución normal estándar.




Figura 3.2 Comparativa entre algunas de las funciones de activación más utilizadas en arquitecturas de aprendizaje profundo. Se observa la saturación de las funciones sigmoide y tangente hiperbólica en valores extremos, frente al comportamiento lineal de ReLU para $z > 0$ y las transiciones suaves de ELU y GELU en el semiplano negativo.

3.1.2. El perceptrón multicapa

Un **perceptrón multicapa** es uno de los tipos más sencillos de red neuronal en el que las neuronas están conectadas sin ningún ciclo ya que las salidas de las unidades en cada capa se introducen como entradas a la siguiente capa (ver Figura 3.3). De este

modo, la información fluye desde una capa hasta la siguiente, sin conexiones dentro de un mismo nivel. Se distinguen tres tipos de capas:

1. **Capa de entrada.** Introduce el tensor de entrada $\mathbf{x}$ a la red. A diferencia de las siguientes, esta capa no realiza computación, solo distribuye la señal.
2. **Capas ocultas.** Constituyen el núcleo computacional. Realizan transformaciones no lineales sucesivas mediante pesos y funciones de activación. La cantidad de estas capas determina la **profundidad** del modelo.
3. **Capa de salida.** Transforma la última representación oculta en la predicción final. La estructura del vector de salida depende de la naturaleza del problema que la red pretenda resolver. Así, la capa de salida podrá estar formada por una única neurona $\hat{y}$ o por un tensor $[\hat{y}_1, \dots, \hat{y}_k]^T$.

Bajo esta estructura, la red neuronal se define como una función parametrizada f_θ , donde los datos de entrada son el argumento de la función y θ es el espacio de parámetros encapsulado en el conjunto de todos los pesos $\mathbf{W}$ y sesgos $\mathbf{b}$ de la red.




Figura 3.3 Arquitectura de un perceptrón multicapa con dos capas ocultas.

3.1.3. El teorema de aproximación universal

El conjunto de datos de entrenamiento es una colección de datos de entrada y etiquetas $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, que representan una función del mundo real $h(x)$. El objetivo de la red neuronal es adaptar los pesos $\mathbf{W}$ y los sesgos $\mathbf{b}$ (es decir, el conjunto de parámetros θ) para aproximar a la función $h(x)$:

$$f_{\theta}(x) \approx h(x) \quad (3.3)$$

El **teorema de aproximación universal** [29] proporciona la justificación teórica fundamental para el uso de estas redes. Afirma que un perceptrón multicapa con al menos una capa oculta y una función de activación no lineal (acotada y no constante) puede aproximar cualquier función continua definida en un subconjunto compacto de $\mathbb{R}^n$ con un nivel arbitrario de precisión, dado un número suficiente de neuronas.

Esto implica que las redes neuronales **son aproximadores universales**, sin un límite teórico de capacidad. No obstante, esto no garantiza que el algoritmo de entrenamiento sea capaz de **aprender** dicha función. Aunque el MLP pueda, en teoría, representarla, el proceso de aprendizaje puede fallar por dos motivos diferentes.

Primero, el algoritmo de optimización utilizado para el entrenamiento podría no **converger** al conjunto de parámetros correspondiente a la función deseada. Segundo, el algoritmo de entrenamiento podría elegir la función incorrecta debido al **sobreajuste**.

3.2. Entrenamiento de una red neuronal

En esta sección se detalla el proceso de entrenamiento de una red neuronal. Se comienza definiendo el entrenamiento como un problema de minimización de una función determinada, denominada **función coste**. A continuación, se detallan los algoritmos de entrenamiento más habituales y el algoritmo de retropropagación, fundamental para optimizar los pesos de la red durante el entrenamiento.

3.2.1. Funciones coste

Para construir un método de entrenamiento, debe existir una forma de cuantificar cuán buena es la aproximación que la red neuronal hace de la función real h . Matemáticamente, esto se modeliza introduciendo una **función coste** $J(\theta)$ que represente la discrepancia entre la predicción del modelo y las observaciones empíricas $\mathbf{y}$.

Desde una perspectiva estadística, minimizar la función coste es equivalente a realizar una **estimación de máxima verosimilitud**. Es decir, buscamos la configuración

óptima de parámetros $\hat{\theta}$ que maximice la probabilidad conjunta de observar el conjunto de datos $\mathcal{D}$ dado el modelo:

$$\hat{\theta} = \arg \max_{\theta} P(\mathcal{D}|\theta). \quad (3.4)$$

En base a este criterio, se construyen diferentes funciones de pérdida en función de la tarea a la que se enfrente el modelo [30]. A continuación se enumeran algunos ejemplos:

1. **Regresión univariante.** El objetivo es predecir una variable objetivo escalar $y \in \mathbb{R}$. La función coste es el **error cuadrático medio** (MSE, *Mean Squared Error*):

$$J(\theta) = \sum_{i=1}^I (y_i - f_{\theta}(\mathbf{x}^{(i)}))^2. \quad (3.5)$$

2. **Clasificación binaria.** La variable objetivo es discreta $y \in \{0, 1\}$. La red utiliza una función de activación sigmoide para acotar la salida al intervalo $[0, 1]$, interpretándose como una probabilidad de Bernoulli. La función de coste es la **entropía cruzada binaria**:

$$J(\theta) = - \sum_{i=1}^I [y_i \log(f_{\theta}(\mathbf{x}^{(i)})) + (1 - y_i) \log(1 - f_{\theta}(\mathbf{x}^{(i)}))]. \quad (3.6)$$

3. **Clasificación multiclase.** La variable objetivo puede pertenecer a una de K clases, representándose habitualmente mediante codificación *one-hot*. La red utiliza una función *softmax* para generar una distribución de probabilidad sobre las clases. La función de coste es la **entropía cruzada categórica**:

$$J(\theta) = - \sum_{i=1}^I \sum_{k=1}^K y_{ik} \log(f_{\theta}(\mathbf{x}^{(i)})). \quad (3.7)$$

3.2.2. Ajuste de modelos

La función pérdida depende de los parámetros del modelo. El objetivo de los **algoritmos de optimización** es encontrar el conjunto de parámetros que minimiza la función pérdida.

Descenso del gradiente

Existen muchas familias de algoritmos de optimización, el más sencillo de ellos se conoce como **descenso del gradiente** (*Gradient Descent*), que es un método iterativo de primer orden. El procedimiento consta de dos pasos fundamentales en cada iteración [31]:

1. **Cálculo del gradiente.** Se computa el vector de derivadas parciales de la función de coste respecto a los parámetros actuales θ :

$$\nabla_{\theta} J = \frac{\partial J}{\partial \theta} = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \vdots \\ \frac{\partial J}{\partial \theta_n} \end{bmatrix} \quad (3.8)$$

2. **Actualización de parámetros.** Se ajustan los parámetros moviéndose en la dirección del descenso más pronunciado (el gradiente negativo):

$$\theta \leftarrow \theta - \alpha \nabla_{\theta} J \quad (3.9)$$

donde el escalar positivo α denota la **tasa de aprendizaje** (LR, *Learning Rate*) que determina la magnitud del paso de actualización.

Cuando se alcanza un punto crítico, la superficie se aplana y el gradiente tiende a cero. Teóricamente, en este punto los parámetros dejan de cambiar. Sin embargo, en redes profundas, el gradiente cero no garantiza un mínimo global; el modelo puede converger a un mínimo local o, más frecuentemente en alta dimensionalidad, estancarse en puntos de silla.

Uno de los mayores problemas del descenso del gradiente es que el punto al que converge está totalmente determinado por el punto de partida. El **descenso del gradiente estocástico** (SGD, *Stochastic Gradient Descent*) intenta solucionar este problema añadiendo algo de ruido al gradiente en cada paso [32]. Si bien la trayectoria de la solución desciende en promedio, en una iteración dada la dirección del vector de actualización no coincide necesariamente con la de máximo descenso.

El optimizador Adam

Aunque el SGD mitiga la convergencia hacia mínimos locales, presenta dificultades cuando la superficie de la función de coste tiene curvaturas muy asimétricas. Para resolver esto, han surgido algoritmos con tasas de aprendizaje adaptativas. El más destacado y utilizado en la literatura actual es Adam (*Adaptive Moment Estimation*) [33]. Adam combina dos conceptos fundamentales:

- Utiliza una **media móvil exponencial** del gradiente (primer momento) para suavizar la trayectoria de actualización, ganando inercia en las direcciones consistentes.
- **Propagación de la raíz cuadrada media.** Utiliza una media móvil exponencial del gradiente al cuadrado (segundo momento) para penalizar las actualizaciones en dimensiones con gradientes muy pronunciados y acelerarlas en dimensiones más planas.

El Algoritmo 1 muestra detalladamente el funcionamiento de este método de optimización:

Algoritmo 1 Algoritmo de Optimización Adam

Entrada: α : Tasa de aprendizaje

Entrada: $\beta_1, \beta_2 \in [0, 1)$: Hiperparámetros de tasas de decaimiento exponencial

Entrada: ε : Constante para evitar la división por cero

Entrada: $J(\theta)$: Función de coste objetivo

Entrada: θ_0 : Vector de parámetros iniciales

```

1:  $m_0 \leftarrow 0$                                 ▷ Inicialización del vector del primer momento
2:  $v_0 \leftarrow 0$                                 ▷ Inicialización del vector del segundo momento
3:  $t \leftarrow 0$                                     ▷ Inicialización del contador de iteraciones
4: mientras el criterio de parada no se cumpla hacer
5:    $t \leftarrow t + 1$ 
6:    $g_t \leftarrow \nabla_{\theta} J(\theta_{t-1})$ 
7:    $m_t \leftarrow \beta_1 m_{t-1} + (1 - \beta_1) g_t$ 
8:    $v_t \leftarrow \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ 
9:    $\hat{m}_t \leftarrow \frac{m_t}{1 - \beta_1^t}$ 
10:   $\hat{v}_t \leftarrow \frac{v_t}{1 - \beta_2^t}$ 
11:   $\theta_t \leftarrow \theta_{t-1} - \frac{\alpha}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t$ 
12: fin mientras
13: devolver  $\theta_t$ 

```

Retropropagación

El procedimiento computacional para determinar el término $\nabla_{\theta} J$ se conoce como **retropropagación** (*backpropagation*). Este método aplica recursivamente la regla de la cadena desde la capa de salida hacia la entrada [31].

Matemáticamente, para un peso individual w_{ij}^l de la capa l , el gradiente se descompone en términos locales:

$$\frac{\partial J}{\partial w_{ij}^l} = \frac{\partial J}{\partial z_i^l} \frac{\partial z_i^l}{\partial w_{ij}^l} = \delta_i^l x_j^{l-1} \quad (3.10)$$

donde δ_i^l representa el término de error retropropagado para la neurona i , y x_j^{l-1} es la activación proveniente de la neurona j de la capa previa. Esta descomposición permite reutilizar los cálculos de derivadas parciales, reduciendo la complejidad computacional linealmente con respecto al número de pesos [31].

Este algoritmo es extremadamente eficiente y se divide en dos etapas secuenciales: la **propagación hacia delante** y la **propagación hacia atrás**.

3.3. Redes neuronales convolucionales

En la sección anterior se introdujeron las redes neuronales completamente conectadas con un solo camino entrada $\rightarrow$ salida. En esta sección introduciremos las **redes neuronales convolucionales** (CNN, *Convolutional Neural Networks*), redes especializadas en el procesamiento de datos de imágenes. Existen numerosas razones que motivan este tipo de arquitecturas frente a las densas [30]:

1. Las imágenes tienen una **dimensionalidad elevada**. Una imagen estándar de resolución 224×224 con tres canales de color constituye un tensor de entrada de dimensión 150.528. Las capas ocultas en las redes completamente conectadas suelen tener mayores dimensiones que los datos de entrada, provocando que el número de pesos exceda los 22.000 millones hasta en redes poco profundas [30].
2. Los píxeles cercanos en una imagen están **altamente relacionados**. Las arquitecturas MLP, al aplanar el tensor de entrada en un vector unidimensional, destruyen la información espacial, tratando la distancia entre píxeles vecinos igual que la de píxeles en extremos opuestos.

3. La interpretación de una imagen es invariante bajo transformaciones geométricas. Un árbol sigue siendo un árbol aunque se traslade un píxel a la izquierda. Esta operación cambia completamente la red, haciendo que una red MLP deba aprender todas las posibles configuraciones equivalentes de píxeles, resultando en una ineficiencia sistemática.

Las redes convolucionales tratan cada región local de la imagen de forma independiente, usando parámetros compartidos a lo largo de toda la imagen. Utilizan menos parámetros que las capas completamente conectadas y son capaces de aprender la dependencia espacial entre los píxeles.

3.3.1. Capas convolucionales

Las capas convolucionales son el elemento fundamental de las CNN. Consisten en una serie de filtros, llamados **kernels** que se aplican de manera deslizante sobre el tensor de entrada. Estos kernels están definidos por una matriz de pesos que se optimiza durante el entrenamiento [34]. Dada una imagen bidimensional I como entrada, y un kernel K , la convolución se define como:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n), \quad (3.11)$$

S se define como **mapa de características** (*feature map*). Cada elemento de S se calcula mediante el producto escalar entre la matriz del kernel y la región local del tensor de entrada (ver Figura 3.4).

3.3.2. *Stride*, *padding* y *pooling*

En la convolución original, el kernel se desplaza un píxel hacia la derecha o un píxel hacia abajo en cada iteración. Cada uno de estos desplazamientos se conoce como *stride* y en la convolución estándar este parámetro es igual a 1. El efecto principal de un *stride* mayor es un aumento del campo receptivo de la salida a costa de una reducción en su dimensionalidad. Por ejemplo, con un *stride* de 2, el filtro se mueve dos píxeles por paso, lo que resulta en una salida aproximadamente cuatro veces menor en área que la entrada (ver Figura 3.5).




Figura 3.4 Ejemplo de una convolución 2D. El kernel actúa como una matriz de pesos aprendibles durante el entrenamiento que extrae características locales.

Por defecto, las operaciones de convolución reducen el tamaño de la salida respecto a la entrada (incluso con $stride = 1$). El *padding* soluciona esto añadiendo filas y columnas de ceros alrededor de los bordes del tensor de entrada antes de aplicar la convolución. El *padding* permite mantener la dimensionalidad y procesar los bordes de la imagen sin añadir información espuria a la entrada. Dado un *stride* S , dimensión de *padding* P y tamaño de filtro K , la dimensión de salida se calcula como:

$$\text{Output}_{dim} = \left\lfloor \frac{\text{Input}_{dim} + 2P - K}{S} \right\rfloor + 1. \quad (3.12)$$

Las capas *pooling* están diseñadas para aumentar el campo receptivo de las neuronas. Operan dividiendo la entrada en una rejilla y aplicando una operación de agregación distinta sobre cada celda [34]. Existen tres variantes principales:

- **Max Pooling.** Es el tipo más común. Su funcionamiento consiste en seleccionar únicamente la unidad con el valor de activación más alto dentro del campo receptivo local, descartando el resto.
- **Average Pooling.** Calcula el valor medio de todas las activaciones dentro del campo receptivo. A diferencia del *Max Pooling*, que busca características domi-




Figura 3.5 Comparación visual del efecto del *stride* en la convolución. Un *stride*=1 reduce la dimensión de 5×5 a 4×4, mientras que un *stride*=2 la reduce a 2×2. En ambos casos se aplica *padding*. Se muestran además las dimensiones de la salida en base a la Ecuación 3.12.

nantes, este suaviza la representación local.

- **Global Average Pooling.** Es una forma extrema de reducción de dimensionalidad. Aquí, la región de *pooling* cubre todo el canal de entrada. Genera un único valor por cada mapa de características. Generalmente se coloca al final de la parte convolucional de una CNN.

3.3.3. Estructura de una red convolucional

La Figura 3.6 muestra la estructura de una CNN básica de clasificación. De forma general las redes convolucionales comparten dos bloques funcionales que procesan la información de manera jerárquica:

1. **Bloque de extracción de características.** Esta es la fase inicial y más profunda de la red, está compuesta por una colección de capas convolucionales y

capas de *pooling*.

- Las capas se apilan secuencialmente para que las unidades más profundas «vean» regiones más grandes de la imagen original. Por ejemplo, mientras una primera capa observa parches de 3×3 píxeles, tras operaciones de *pooling* y convoluciones sucesivas, una capa posterior puede integrar información de áreas mucho mayores (ej. 12×12 píxeles), capturando patrones globales.
- Aumento de la profundidad del volumen. A medida que aumenta la profundidad, aumenta el número de filtros.

2. **Bloque de clasificación.** Formado por capas completamente conectadas. Estas capas actúan como puente entre la salida de la red y las categorías humanas. La última capa utiliza típicamente una función *softmax* para estimar las probabilidades finales de que la entrada pertenezca a cada clase.




Figura 3.6 Ejemplo de arquitectura de una CNN. Las redes convolucionales están formadas por un bloque de extracción de características, formado por capas convolucionales y *pooling*; y por un bloque de clasificación, formado por capas completamente conectadas. Imagen tomada de [35].

3.3.4. Redes completamente convolucionales

Las **redes completamente convolucionales** (FCN, *Fully Convolutional Networks*) constituyen una generalización de las CNN clásicas orientada a tareas de **predicción densa**, en las que se requiere estimar una salida asociada a cada localización espacial de la imagen. Fueron introducidas originalmente en el contexto de la **segmentación semántica**, donde el objetivo consiste en asignar una etiqueta a cada píxel de la imagen en lugar de producir una única clasificación global [36].

A diferencia de las arquitecturas de clasificación, que colapsan la estructura espacial utilizando capas completamente conectadas, las FCN operan exclusivamente mediante operaciones convolucionales y transformaciones locales. En consecuencia, la red define una aplicación

$$f_{\theta} : \mathbb{R}^{H \times W \times C} \longrightarrow \mathbb{R}^{H' \times W' \times C'}, \quad (3.13)$$

que transforma un tensor de entrada directamente en un mapa espacial de salida. Al carecer de capas densas, la red es **equivariante frente a traslaciones**, preservando la topología de la señal original (ver Figura 3.7) [36].




Figura 3.7 Arquitectura de una red completamente convolucional. A diferencia de una red convolucional estándar, donde la última capa produce una salida vectorial, las redes completamente convolucionales son capaces de producir una imagen como salida. El ejemplo mostrado ilustra una red FCN orientada a segmentación. Imagen adaptada de [36].

Este tipo de arquitectura resulta especialmente adecuada para la reconstrucción del

frente de onda en óptica adaptativa. Físicamente, el frente de onda es un campo escalar continuo con fuertes correlaciones espaciales inducidas por la turbulencia atmosférica. Por tanto, la fase en un punto depende de su entorno. Las FCN modelan esta dependencia combinando escalas: las capas iniciales extraen información local, mientras que las capas profundas integran dependencias de largo alcance. Este proceso se realiza sin necesidad de destruir la organización espacial de la señal en ningún punto de la red.

3.4. Estrategias de regularización

Uno de los problemas centrales dentro del aprendizaje automático es la generalización: la capacidad de un modelo de hacer predicciones en datos nunca vistos. Muchas de las estrategias utilizadas para afrontar este problema están diseñadas explícitamente para reducir el error en los conjuntos de prueba, a expensas de aumentarlo en los datos de entrenamiento. Estas estrategias se conocen de forma colectiva como **regularización**.

3.4.1. Dropout

El **dropout** es un método de regularización potente y computacionalmente barato. Durante la fase de entrenamiento, el *dropout* establece a cero aleatoriamente una fracción de las neuronas de una capa en cada iteración, junto con sus conexiones correspondientes (ver Figura 3.8). La probabilidad de que una neurona sea retenida se define por un hiperparámetro $p \in (0, 1]$, comúnmente establecido en 0,5 para las capas ocultas. Matemáticamente, equivale a multiplicar el vector de activaciones por una máscara binaria cuyas entradas siguen una distribución de Bernoulli de parámetro p [31].

El *dropout* rompe la **dependencia mutua** entre neuronas. Al desactivarlas al azar, evitamos que una neurona solo aprenda a corregir los errores de sus compañeras, obligando a cada una a extraer información útil por sí misma. Durante la fase de inferencia, todas las neuronas permanecen activas, pero los pesos de salida se escalan por el factor p para mantener el valor esperado de las activaciones. Desde una perspectiva teórica, esta técnica puede interpretarse como un método eficiente para entrenar y promediar un gran ensamblaje de subredes que comparten pesos [31].




Figura 3.8 Representación del funcionamiento del *dropout*. El ensamblaje está formado por los modelos en los que se eliminan neuronas no pertenecientes a la capa de salida.

3.4.2. Normalización por lotes

La **normalización por lotes** o *batch normalization* es una técnica diseñada para estabilizar y acelerar el entrenamiento de redes profundas. Históricamente, se propuso para mitigar el **desplazamiento de covariables interno**, es decir, los continuos cambios en la distribución de las activaciones de las capas ocultas a medida que los pesos de las capas previas se actualizan [37].

Dada una capa específica y un subconjunto de datos o *mini-batch* de tamaño m , la normalización se aplica a cada dimensión de activación de forma independiente. El proceso consta de dos pasos principales. Primero, se estandarizan los valores utilizando la media μ_B y la varianza σ_B^2 empíricas del *mini-batch*:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad (3.14)$$

donde ε es una constante pequeña añadida para garantizar la estabilidad numérica evitando la división por cero. Segundo, dado que forzar a las activaciones a tener media nula y varianza unitaria podría limitar severamente la capacidad de representación de la red (por ejemplo, restringiendo la región operativa de una función de activación no lineal), se introduce una transformación afín. Para ello, se utilizan dos parámetros entrenables por cada canal de activación: un factor de escala γ y un sesgo de desplazamiento β :

$$y_i = \gamma \hat{x}_i + \beta. \quad (3.15)$$

Durante el despliegue del modelo en la fase de inferencia, las estadísticas del lote se sustituyen por estimaciones de la media y varianza poblacionales, calculadas mediante medias móviles a lo largo de todo el conjunto de entrenamiento [37].

3.4.3. Parada temprana

A medida que una red neuronal se entrena durante múltiples iteraciones o épocas, el error de la función de coste evaluada sobre el conjunto de entrenamiento tiende a disminuir monótonamente. Sin embargo, el error evaluado sobre un conjunto de validación independiente típicamente desciende hasta alcanzar un mínimo, tras el cual comienza a aumentar (ver Figura 3.9). Este punto de inflexión marca el inicio del sobreajuste.

La **parada temprana** (*early stopping*) es una forma de regularización en el tiempo que explota directamente este comportamiento. El algoritmo monitoriza una métrica objetivo en el conjunto de validación al final de cada época. El entrenamiento se interrumpe automáticamente cuando dicha métrica deja de mejorar durante un número predefinido de épocas consecutivas, parámetro conocido como **paciencia**.

Tras la interrupción, el algoritmo descarta los pesos del modelo actual y restaura los parámetros correspondientes a la época que produjo el mejor rendimiento histórico en validación. Esta estrategia es altamente eficiente a nivel computacional y elimina la necesidad de tratar el número total de épocas de entrenamiento como un hiperparámetro que deba ser ajustado.

3.4.4. Reducción de la tasa de aprendizaje en estancamiento

Aunque el ajuste de la tasa de aprendizaje (α) introducido en el descenso del gradiente pertenece al dominio de la optimización, su modulación dinámica durante el entrenamiento actúa como un mecanismo para estabilizar la convergencia y mejorar la generalización del modelo.

La estrategia de **reducción de la tasa de aprendizaje en estancamiento** consiste en monitorizar una métrica de evaluación, habitualmente la función de coste en el conjunto de validación. Si esta métrica deja de mejorar durante un número predeterminado de épocas (conocido como *paciencia*, hiperparámetro homónimo pero independiente al




Figura 3.9 Representación de las curvas de aprendizaje respecto al número de iteraciones (épocas). La parada temprana minimiza el error en el conjunto de validación para evitar el sobreajuste.

de la parada temprana), el algoritmo asume que el optimizador ha quedado atrapado oscilando alrededor de un mínimo o que ha alcanzado una región plana.

Para forzar al modelo a descender hacia el fondo exacto de ese mínimo, la tasa de aprendizaje se multiplica por un factor de reducción fraccionario (por ejemplo, 0,5). Al disminuir bruscamente la magnitud del paso de actualización de los pesos, se mitigan las oscilaciones y se permite que la red neuronal realice ajustes mucho más finos.

Esta técnica iterativa permite combinar lo mejor de ambos enfoques: una tasa de aprendizaje inicialmente alta que acelera el aprendizaje global y ayuda a escapar de mínimos locales superficiales en las primeras épocas, seguida de reducciones drásticas sucesivas que estabilizan el modelo. En las curvas de aprendizaje, el efecto de esta estrategia se manifiesta con caídas abruptas o «escalones» en el error de validación en el instante exacto en el que se reduce la tasa de aprendizaje.

4. Metodología y Diseño Experimental

4.1. Entorno de simulación

La generación de datos mediante la plataforma DASP, así como el entrenamiento y validación de las arquitecturas, se ejecutaron en un servidor equipado con un procesador Intel Xeon E5-1650 v3 (6 núcleos) y 128 GB de RAM. Para acelerar las operaciones matriciales, se utilizaron dos GPUs NVIDIA GeForce GTX TITAN X con 12 GB de VRAM cada una.

4.2. Parametrización y generación del conjunto de datos

Las simulaciones reproducen un sistema GLAO en régimen de observación solar. Los conjuntos de datos se generaron mediante la plataforma DASP, variando el parámetro de Fried y la altitud de las capas turbulentas. La escala externa de la atmósfera se fija en $L_0 = 25$ m y la escala interna se asume nula ($l_0 \rightarrow 0$). Para evitar la contaminación de datos (*data leakage*), el espacio de parámetros se dividió en dos conjuntos independientes:

- **Conjunto de entrenamiento.** Diseñado para enseñar al modelo la casuística base de la turbulencia. El parámetro de Fried se varió en el rango $r_0 \in [8, 20]$ cm con incrementos de 1 cm. Paralelamente, la altura de la capa turbulenta barrió el intervalo $[0, 2500]$ m en pasos de 50 m. Se ejecutaron 50 iteraciones temporales

por cada combinación, generando un volumen total de 32.500 muestras.

- **Conjuntos de prueba.** Para evaluar el rendimiento de la reconstrucción, se generaron 9 conjuntos de validación independientes, cada uno con un valor fijo de r_0 comprendido entre 10 cm y 18 cm. A diferencia del conjunto de entrenamiento, las alturas de simulación se extendieron hasta los 5.000 m en pasos de 250 m. Esta discrepancia en el dominio de las alturas tiene como objetivo validar la capacidad del modelo para generalizar y realizar predicciones sobre condiciones atmosféricas no vistas durante su entrenamiento.

La configuración geométrica de todas las simulaciones así como la estructura de los datos se detallan en la siguiente sección.

4.3. Estructuración de los datos

Los datos simulados se almacenan utilizando el estándar HDF5. Este formato permite encapsular en un único archivo diferentes tensores multidimensionales, separando las imágenes focales crudas captadas por las cámaras CCD, los vectores de pendientes locales y los mapas de fase teóricos. La Tabla 4.1 recoge todos los tensores almacenados en esta estructura, así como su dimensión y su descripción física.

4.3.1. Configuración de los sensores

El sistema de óptica adaptativa simulado emplea una configuración basada en 7 sensores Shack-Hartmann operando sobre granulación solar. Físicamente, seis de estos sensores se distribuyen formando un anillo periférico, mientras que el séptimo se posiciona alineado con el eje central (ver Figura 4.1). Durante la fase de inferencia, la red neuronal se alimenta exclusivamente de la información extraída de los sensores periféricos pues su objetivo es reconstruir la turbulencia sobre el sensor central.

Como se puede observar en la figura, las imágenes de los sensores 1 a 6 presentan una geometría anular que refleja el oscurecimiento central del telescopio (sombra del espejo secundario). Cada subapertura de la matriz de microlentes forma una imagen de la granulación solar, dando lugar a una textura continua y de bajo contraste sobre la pupila. Por otro lado, el sensor central muestra un patrón de franjas horizontales.

Esto se debe a que el eje no se utiliza como fuente de datos, de modo que el DASP simplemente aloja un tensor de ruido o valor residual en dicha capa de la matriz de datos.




Figura 4.1 Imágenes simuladas en el plano focal de los siete WFS Shack-Hartmann. Los seis sensores periféricos muestran la imagen formada por la matriz de microlentes sobre una fuente extendida (granulación solar), recortada por la pupila anular del telescopio. La oscuridad central corresponde a la sombra del espejo secundario. El sensor central S6 no se utiliza como entrada del modelo, pues constituye precisamente la dirección sobre la que se desea reconstruir el frente de onda.

Tensor	Dimensiones	Descripción
<code>data_slope</code>	$N \times 312 \times 7$	Pendientes locales. Vectores de medida de los 7 sensores WFS. Contienen 312 valores por sensor correspondientes a los desplazamientos intercalados $(s_{x,1}, s_{y,1}, s_{x,2}, s_{y,2} \dots)$ de 156 subaperturas válidas. Constituyen la entrada de las arquitecturas MLP.
<code>data</code>	$N \times 360 \times 360 \times 7$	Imágenes recibidas por los 7 WFS. Los sensores están configurados en disposición circular con uno situado en el centro. Este no se utiliza como fuente de datos pues es el que se quiere inferir. Los píxeles en las regiones periféricas tienen valores nulos, debido a la ausencia de luz. Constituyen la entrada para arquitecturas puramente convolucionales.
<code>label</code>	$N \times 90 \times 90 \times 7$	Fase teórica. Turbulencia simulada sobre cada uno de los WFS. El mapa correspondiente a la dirección central actúa como el objetivo ideal a inferir.
<code>zerns</code>	$N \times 153$	Coefficientes modales. Valores de los 153 primeros modos de Zernike correspondientes al sensor central. Constituye la variable objetivo para el entrenamiento de redes MLP, ofreciendo una alternativa computacionalmente eficiente frente a la reconstrucción directa de los mapas de fase.
<code>recovered_DASP</code>	$N \times 90 \times 90$	Baseline. Fase del eje central reconstruida mediante el estimador de mínimos cuadrados. Representa el límite de rendimiento tradicional frente al cual se evaluarán las métricas de error de las ANN propuestas.

Tabla 4.1 Estructura dimensional y descripción física de los tensores de telemetría extraídos. N es el número total de muestras. En el conjunto de entrenamiento $N = 32.500$ mientras que en los conjuntos de prueba $N = 1.000$.

4.4. Planteamiento y descripción de los modelos

La información almacenada durante las simulaciones incluye tanto medidas físicas en bruto como características geométricas procesadas. Esta variedad de datos permite abordar el problema de la reconstrucción mediante dos enfoques complementarios.

El primer enfoque, de carácter paramétrico, se basa en redes MLP. Este método utiliza como variable de entrada los vectores aplanados de las pendientes locales (`data_slope`). El objetivo del modelo es inferir un vector de salida compuesto por los 153 primeros coeficientes de Zernike correspondientes al sensor central (`zerns`).

El segundo enfoque, de carácter espacial, emplea redes neuronales completamente convolucionales para procesar directamente las imágenes focales puras (`data`) y predecir el mapa de fase bidimensional continuo (`label`). Aunque este modelo requiere un mayor esfuerzo computacional, evita la pérdida de información espacial que se produce al simplificar las manchas de luz a meros vectores de centroides.

A lo largo de este capítulo se detallará el diseño, el preprocesamiento de los datos y las estrategias de evaluación para ambos métodos, comenzando por las arquitecturas paramétricas.

4.4.1. Enfoque paramétrico

En esta sección detallaremos el enfoque basado en redes MLP para la predicción de los modos de Zernike correspondientes al sensor central.

Para ello, se toma como entrada el tensor `data_slope` $\mathbf{X} \in \mathbb{R}^{N \times 312 \times 7}$. Se recorta el sensor central, obteniendo un tensor de dimensiones $N \times 312 \times 6$. A continuación, ese tensor se aplanar a un vector de 1872 características (312×6). El objetivo $\mathbf{Y}$ se define como los 153 modos de Zernike correspondientes al sensor central extraídos de `zerns`. Sus dimensiones son $N \times 153$.

Debido a que no se conoce a priori qué tipo de arquitectura MLP puede ofrecer mejores resultados para esta tarea de regresión, este estudio plantea un enfoque comparativo entre un modelo base (*baseline*) y seis arquitecturas alternativas.

Descripción de las arquitecturas

La descripción en detalle de las arquitecturas se encuentra en la Tabla 4.2. A continuación se discuten sus características principales:

1. **Baseline.** Se trata de la arquitectura más simple. Consiste en una arquitectura de tres capas ocultas con una reducción dimensional secuencial, empleando la función de activación estándar ReLU y una tasa de aprendizaje base de 1×10^{-3} .
2. **Wider** (mayor anchura). Consiste en una expansión de la dimensionalidad interna. Una mayor cantidad de neuronas por capa, facilitando la captura de correlaciones cruzadas complejas entre los distintos modos en el espacio de Zernike.
3. **Deeper** (mayor profundidad). Expande la red hasta las 6 capas ocultas para evaluar si una jerarquía más profunda modela con mayor fidelidad la estructura no lineal de la turbulencia atmosférica.
4. **Activación ELU.** Sustituye ReLU por ELU (ver Sección 3.1.1). Proporciona gradientes más suaves y permite valores negativos controlados para evitar «neuronas muertas» y favorecer la convergencia [38].
5. **Activación GELU.** Emplea la unidad GELU, cuya curva de transición suave suele superar el rendimiento de ReLU en tareas de regresión continua [39].
6. **Conexiones residuales.** Se introducen conexiones de atajo entre los bloques de capas ocultas. En las redes tradicionales, la salida de la capa L es la entrada de la capa $L+1$. Esta topología permite que la información salte entre capas, realizando una conexión en paralelo y sumando la capa original a la señal procesada [40].
7. **Tasa de aprendizaje acelerada.** Manteniendo la topología del modelo *baseline*, se incrementa la tasa de aprendizaje en un factor de tres, situándola en 3×10^{-3} . Esta configuración pretende explorar la posibilidad de obtener convergencias más rápidas.

Cada modelo se entrena un máximo de 200 épocas en lotes de 64 muestras. Para mitigar el sobreajuste y estabilizar el aprendizaje, se aplican las estrategias de regularización descritas en la Sección 3.4. En particular, se aplica una tasa de *dropout* de 0,1 y parada temprana con paciencia 20 iteraciones. Posteriormente, las dos arquitecturas con menor error de validación se reentrenan durante 500 épocas para compararlas con el método

Modelo	Topología	Params.	Activación	LR
Baseline	1024 → 512 → 256 → 128	2.634.264	ReLU	1×10^{-3}
<i>Wider</i>	2048 → 1024 → 512 → 256	6.844.632	ReLU	1×10^{-3}
<i>Deeper</i>	1024 → 1024 → 512 → 512 → 256 → 128	3.952.064	ReLU	1×10^{-3}
ELU	1024 → 512 → 256 → 128	2.634.264	ELU	1×10^{-3}
GELU	1024 → 512 → 256 → 128	2.634.264	GELU	1×10^{-3}
Residual	512 → 2 × Res[512,512] → 256 → 128	2.201.096	ReLU	1×10^{-3}
Fast LR	1024 → 512 → 256 → 128	2.634.264	ReLU	3×10^{-3}

Tabla 4.2 Configuración de las arquitecturas propuestas. Se resaltan en negrita las variaciones que presenta cada una respecto al modelo Baseline. LR representa la tasa de aprendizaje inicial.

de mínimos cuadrados.

Para optimizar la convergencia, se implementa una reducción dinámica de la tasa de aprendizaje detallada en la Sección 3.4.4. Este algoritmo monitoriza la función de coste en validación y reduce la tasa de aprendizaje a la mitad si no se detecta mejora tras 8 épocas.

Preprocesamiento de los datos

Uno de los pasos fundamentales en el entrenamiento de cualquier red neuronal es la **normalización**. No obstante, aplicar técnicas de normalización global a todos los modos no es una técnica viable pues estos presentan una distribución energética no uniforme. Noll demostró teóricamente en 1976 [41] que la varianza esperada de los coeficientes de Zernike decae de forma drástica y no lineal a medida que aumenta el orden radial del polinomio. En la práctica, esto implica que los modos de bajo orden, como la inclinación global del frente (*tip* y *tilt*), presentan amplitudes físicas que son varios órdenes de magnitud superiores a las aberraciones de alto orden.

Para mitigar este desequilibrio y estabilizar el entrenamiento, se ha aplicado una **estandarización Z-score** independiente por característica, tanto a las entradas del modelo como a los objetivos. Para garantizar la rigurosidad metodológica y evitar el *data leakage*, la media (μ_j) y la desviación típica (σ_j) de cada característica j se calculan

utilizando de forma exclusiva el conjunto de entrenamiento. Posteriormente, cada valor $z_{i,j}$ se transforma a su versión estandarizada $z_{i,j}^{\text{norm}}$ mediante la siguiente expresión:

$$z_{i,j}^{\text{norm}} = \frac{z_{i,j} - \mu_j}{\sigma_j + \varepsilon}, \quad \varepsilon = 10^{-8}, \quad (4.1)$$

Esta normalización garantiza que tanto las variables de entrada como las de salida operen en una escala de media cero y varianza uno, evitando la saturación de las funciones de activación y mejorando la estabilidad del optimizador.

Finalmente, durante la fase de inferencia, las predicciones del modelo se desnormalizan aplicando la transformación inversa (multiplicando por σ_j y sumando μ_j) para recuperar las amplitudes físicas originales necesarias para el control del espejo deformable.

Función coste

Dado que el enfoque paramétrico constituye un problema de regresión múltiple continua, se ha seleccionado el error cuadrático medio como función de coste a minimizar durante el entrenamiento (ver Sección 3.2.1). Esta métrica es especialmente adecuada para sistemas de OA, ya que su formulación cuadrática penaliza severamente las grandes desviaciones en la estimación de la fase, garantizando una convergencia más estricta del frente de onda corregido. La función de pérdida J_{MSE} se evalúa para cada lote de datos según la siguiente expresión:

$$J_{\text{MSE}} = \frac{1}{N \cdot M} \sum_{i=1}^N \sum_{j=1}^M (\hat{z}_{i,j} - z_{i,j}^{\text{norm}})^2$$

Donde:

- N representa el tamaño del lote.
- M es el número total de características a predecir (los 153 modos de Zernike).
- $\hat{z}_{i,j}$ es el valor predicho por la red lineal de salida para el modo j de la muestra i .
- $z_{i,j}^{\text{norm}}$ constituye el valor real esperado (*ground truth*), previamente normalizado.

La minimización de esta función de coste se lleva a cabo mediante el algoritmo de optimización Adam descrito en la Sección 3.2.2.

Métricas de evaluación

Las métricas son las funciones clave para evaluar el desempeño de nuestros modelos y compararlos cuantitativamente. Al tratarse de un problema de regresión, se han elegido como métricas de evaluación:

1. **Raíz del Error Cuadrático Medio (RMSE).** Definida como la raíz cuadrada de la media de los errores al cuadrado, penaliza de forma cuadrática las desviaciones más grandes:

$$\text{RMSE} = \sqrt{\frac{1}{N \cdot M} \sum_{i=1}^N \sum_{j=1}^M (z_{i,j} - \hat{z}_{i,j})^2} \quad (4.2)$$

2. **Error Absoluto Medio (MAE).** Proporciona la magnitud promedio del error absoluto en la estimación de la fase, ofreciendo una interpretación directa y lineal sobre la precisión esperada del modelo en la reconstrucción de los coeficientes de Zernike. Al no elevar los residuos al cuadrado, es más robusto frente a predicciones extremas aisladas que el RMSE.

$$\text{MAE} = \frac{1}{N \cdot M} \sum_{i=1}^N \sum_{j=1}^M |z_{i,j} - \hat{z}_{i,j}| \quad (4.3)$$

Proyección espacial y métricas en el dominio de la fase

Las arquitecturas descritas previamente infieren directamente un vector de coeficientes de Zernike ($\hat{\mathbf{a}}$) a partir de las pendientes locales. Sin embargo, el estimador tradicional de mínimos cuadrados, extraído del simulador DASP (`recovered_DASP`), genera la reconstrucción del frente de onda en forma de un mapa de fase espacial bidimensional.

Para realizar una comparación bajo un mismo marco de referencia, es necesario proyectar las predicciones modales de la red neuronal hacia el dominio espacial. Matemáticamente, la fase reconstruida por la red neuronal sobre los P píxeles válidos de la pupila, denotada como el vector columna $\Phi_{\text{MLP}} \in \mathbb{R}^P$, se obtiene mediante la combinación lineal de los coeficientes predichos y una matriz de transición espacial $\mathbf{Z} \in \mathbb{R}^{M \times P}$:

$$\Phi_{\text{MLP}} = \mathbf{Z}^T \hat{\mathbf{a}}, \quad (4.4)$$

donde $\hat{\mathbf{a}} \in \mathbb{R}^M$ contiene los $M = 153$ coeficientes predichos por el modelo.

Como se definió teóricamente en la Sección 2.2.4, los polinomios de Zernike son funciones continuas y ortogonales sobre el círculo unidad. El enfoque más intuitivo para construir la matriz de transformación $\mathbf{Z}$ consistiría en evaluar estas funciones píxel a píxel sobre la cuadrícula de simulación. No obstante, este enfoque teórico presenta dos graves deficiencias:

1. **Errores de discretización.** Al evaluar funciones continuas sobre una cuadrícula finita de baja resolución (en este caso, una malla de 90×90 píxeles), se introducen errores de *aliasing* numérico¹.
2. **Geometría anular de la pupila.** El telescopio simulado presenta un oscurecimiento central debido a la sombra del espejo secundario. Los polinomios estándar de Zernike pierden sus propiedades exactas de ortogonalidad al ser aplicados sobre dominios truncados o anulares.

Para evitar estos problemas, en esta investigación se ha prescindido de la formulación analítica en favor de una **base espacial empírica**. Esta base se construye matricialmente utilizando los valores exactos de referencia generados internamente por el propio simulador. Sean $\mathbf{a}_{\text{true}}$ los coeficientes ideales simulados y Φ_{true} los correspondientes mapas de fase teóricos extraídos de DASP; la matriz $\mathbf{Z}$ se deriva a través de la transformación que mapea un espacio en el otro. Esto equivale a resolver el sistema lineal sobredeterminado² $\mathbf{a}_{\text{true}}^T \mathbf{Z} = \Phi_{\text{true}}^T$ mediante una optimización por mínimos cuadrados, cuya solución analítica es:

$$\mathbf{Z} = (\mathbf{a}_{\text{true}} \mathbf{a}_{\text{true}}^T)^{-1} \mathbf{a}_{\text{true}} \Phi_{\text{true}}^T \quad (4.5)$$

Esta matriz empírica $\mathbf{Z}$ «aprende» implícitamente a ignorar los píxeles nulos de la sombra central y absorbe cualquier particularidad de renderizado o discretización interna del motor DASP. Una vez calculada, se aplica sistemáticamente a las predicciones modales de las redes neuronales. De este modo, el RMSE y el MAE se evalúan comparando directamente los mapas espaciales reconstruidos frente a la fase teórica ideal.

¹El *aliasing* es un fenómeno numérico que ocurre al muestrear una señal continua en una cuadrícula discreta con resolución insuficiente para capturar sus variaciones más rápidas, distorsionando la señal digitalizada.

²Un sistema con más ecuaciones que incógnitas.

4.4.2. Enfoque espacial

En esta sección se detalla el enfoque basado en redes convolucionales para la reconstrucción del frente de onda del sensor central a partir de la información procedente de los sensores Shack–Hartmann periféricos. A diferencia del enfoque paramétrico descrito previamente, donde la red predice directamente un vector de coeficientes modales de Zernike, la red FCN realiza una regresión imagen-a-imagen. La entrada es un tensor bidimensional multicanal y la salida es un mapa espacial bidimensional de fase. En consecuencia, el problema deja de formularse en el espacio modal y pasa a plantearse directamente en el dominio físico de la fase sobre la pupila.

Descripción de la arquitectura

La arquitectura implementada es una FCN de tipo codificador compacto. Se toma como entrada $\mathbf{X}$ un tensor de dimensiones $N \times 360 \times 360 \times 6$, construido aislando exclusivamente las imágenes focales de los seis sensores periféricos contenidas en el tensor `data`. El objetivo espacial a predecir, Φ , es un tensor de dimensiones $N \times 90 \times 90 \times 1$, correspondiente a los mapas de fase teóricos del sensor central extraídos del tensor `label`.

La reducción de la dimensionalidad se consigue mediante dos convoluciones estridadas con paso 2, evitando capas de *pooling* (ver Sección 3.3.2). Dado que la reconstrucción de la fase es un problema de regresión en el que la posición espacial exacta de las aberraciones es crítica, el *pooling* tradicional resulta perjudicial al descartar información local de forma determinista.

La topología exacta de la arquitectura está representada en la Figura 4.2. El *stride* de cada capa convolucional está representado por la letra S en la imagen. Todas las capas convolucionales emplean `padding='same'`. Recordando la Ecuación 3.12, esto implica que para $S = 1$, las dimensiones espaciales se conservan, mientras que para $S = 2$ se produce una reducción aproximadamente a la mitad.

Cada convolución está seguida por una normalización por lotes y una función de activación ReLU. Finalmente, la capa de salida emplea una convolución 1×1 con activación lineal, al tratarse de una tarea de regresión continua.

La principal ventaja de una FCN frente a una MLP radica en que la convolución ex-




Figura 4.2 Arquitectura convolucional empleada para la reconstrucción del frente de onda. La reducción espacial se realiza mediante convoluciones con *stride* $S = 2$, sin utilizar capas de *pooling*. Las siglas BN representan la normalización por lotes (*Batch Normalization*) que, junto con la activación ReLU, se aplican tras cada una de las capas convolucionales ocultas.

plota explícitamente la estructura espacial local de la información. Las imágenes de los sensores Shack-Hartmann forman un campo donde la vecindad espacial de los patrones (desplazamientos, elongaciones e intensidades) tiene un significado físico directo. Al imponer conectividad local y compartir pesos espaciales, la red detecta estos patrones ópticos elementales independientemente de su posición en el detector.

Preprocesamiento de los datos

El preprocesamiento implementado difiere del usado en el modelo MLP debido a la distinta naturaleza de las variables de entrada y salida. Como ya se describió, la entrada se construye seleccionando únicamente los seis sensores periféricos del tensor **data**, descartando el canal central. Así, cada muestra de entrada queda descrita por un tensor $\mathbf{X}_i \in \mathbb{R}^{360 \times 360 \times 6}$, mientras que la salida es el último canal del tensor **label**, correspondiente exclusivamente al mapa de fase del sensor central: $\Phi_i \in \mathbb{R}^{90 \times 90 \times 1}$.

Para la entrada no se utiliza una estandarización Z-score, sino una normalización

mínimo-máximo global:

$$X_{i,p,c}^{\text{norm}} = \frac{X_{i,p,c} - X_{\text{mín}}}{X_{\text{máx}} - X_{\text{mín}} + \varepsilon}, \quad \varepsilon = 10^{-8}, \quad (4.6)$$

que mapea todas las entradas al intervalo $[0,1]$. Aquí, p recorre los píxeles espaciales y $c \in \{1, \dots, 6\}$ recorre los sensores periféricos. Los escalares $X_{\text{mín}}$ y $X_{\text{máx}}$ se calculan de forma global sobre todas las muestras del conjunto de entrenamiento y sobre los seis canales simultáneamente.

La aplicación de una normalización global para los seis sensores periféricos es fundamental. Si cada canal se normalizara de forma independiente, se destruiría la información relativa de intensidad lumínica entre ellos, la cual codifica la distribución espacial de la turbulencia. La elección de la escala *min-max* frente al Z-score obedece a la naturaleza geométrica de la señal óptica, caracterizada por un límite inferior estricto (ausencia de luz) y extensas regiones de oscuridad. Al mapear el mínimo global a 0, la normalización *min-max* preserva la dispersión natural del tensor. Por el contrario, el Z-score centraría los datos sobre una media positiva, introduciendo valores negativos artificiales en el fondo nulo y destruyendo la topología física de la entrada.

Para la salida objetivo se utiliza una estandarización global:

$$\Phi_{i,p}^{\text{norm}} = \frac{\Phi_{i,p} - \mu_{\Phi}}{\sigma_{\Phi} + \varepsilon}, \quad (4.7)$$

donde μ_{Φ} y σ_{Φ} se estiman exclusivamente a partir del conjunto de entrenamiento.

A diferencia del enfoque MLP, cada coeficiente modal se estandarizaba por separado debido a la fuerte no uniformidad energética entre modos de Zernike, aquí el objetivo es un campo escalar homogéneo expresado en una única unidad física, el radián. Por ello, el código adopta un único par $(\mu_{\Phi}, \sigma_{\Phi})$ para todo el mapa de fase central. Durante inferencia y evaluación, la salida de la red se desnormaliza para recuperar magnitudes físicas:

$$\hat{\Phi}_{i,p} = \hat{\Phi}_{i,p}^{\text{norm}} (\sigma_{\Phi} + \varepsilon) + \mu_{\Phi}. \quad (4.8)$$

Este paso permite que las métricas finales se expresen en radianes, y no en el espacio normalizado.

El *data leakage* se evita calculando las estadísticas de normalización únicamente sobre los índices de entrenamiento, después de realizar la partición entrenamiento-validación.

El 10 % de las muestras se reserva para validación.

Función de coste y ajuste del modelo

La red se entrena minimizando el error cuadrático medio entre la predicción normalizada y el objetivo normalizado. Si el lote contiene N muestras y cada mapa tiene $H \times W = 90 \times 90$ píxeles, la función de coste puede escribirse como

$$J_{\text{MSE}} = \frac{1}{N \cdot H \cdot W} \sum_{i=1}^N \sum_{u=1}^H \sum_{v=1}^W \left(\hat{\Phi}_{i,u,v}^{\text{norm}} - \Phi_{i,u,v}^{\text{norm}} \right)^2. \quad (4.9)$$

La minimización se realiza mediante el optimizador Adam con tasa de aprendizaje inicial 10^{-3} . Como se justificó para las redes MLP, el uso del MSE es coherente con un problema de reconstrucción de fase pues penaliza cuadráticamente los errores grandes y empuja al modelo a reducir las desviaciones espaciales más severas.

El entrenamiento implementa parada temprana con paciencia de 30 épocas y una reducción adaptativa de la tasa de aprendizaje con paciencia 10 y un factor de reducción de 0,5.

Comparación frente al estimador de mínimos cuadrados

La comparación específica entre la FCN y el estimador de mínimos cuadrados no se formula en el espacio modal, sino directamente en el dominio espacial de la fase. Este es un punto metodológicamente diferente al caso anterior. Mientras que en el enfoque MLP resultaba necesario proyectar los coeficientes de Zernike predichos sobre una base espacial para poder compararlos con la reconstrucción de DASP, en el enfoque convolucional dicha proyección no es necesaria porque tanto la FCN como el método LS producen mapas de fase 90×90 directamente comparables. Para ello, se construyen los residuos espaciales:

$$\mathbf{R}_i^{\text{FCN}} = \hat{\Phi}_i - \Phi_i, \quad \mathbf{R}_i^{\text{LS}} = \Phi_i^{\text{LS}} - \Phi_i. \quad (4.10)$$

Sobre cada muestra i se calcula entonces el error RMS espacial:

$$\text{RMS}_i = \sqrt{\frac{1}{P} \sum_{p=1}^P R_{i,p}^2}, \quad (4.11)$$

donde $P = 90 \times 90$ es el número de píxeles del mapa evaluado. Por tanto, la magnitud comparada no es un RMSE global agregado sobre todo el conjunto, sino un RMS residual **por muestra**. Este detalle es relevante porque preserva la dispersión estadística entre realizaciones individuales.

Una vez obtenido el conjunto $\{\text{RMS}_i\}_{i=1}^N$ para la FCN y para LS, se resume el rendimiento de cada archivo mediante la media y la desviación típica:

$$\overline{\text{RMS}} = \frac{1}{N} \sum_{i=1}^N \text{RMS}_i, \quad \sigma_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\text{RMS}_i - \overline{\text{RMS}})^2}, \quad (4.12)$$

y se calcula el cociente

$$\mathcal{I} = \frac{\overline{\text{RMS}}_{\text{LS}}}{\overline{\text{RMS}}_{\text{FCN}}}, \quad (4.13)$$

de modo que $\mathcal{I} > 1$ indica que la FCN supera al estimador de mínimos cuadrados, al presentar un error residual medio menor. Esta representación es particularmente útil porque transforma la comparación absoluta en una medida relativa de mejora.

5. Resultados y Discusión

Este capítulo valida los modelos propuestos frente al estimador LS mediante dos análisis complementarios. Para el enfoque paramétrico (MLP), se evalúa la reconstrucción modal de los coeficientes de Zernike mediante métricas de regresión escalar (RMSE y MAE). Por otro lado, el enfoque espacial (FCN) se analiza mediante métricas específicas de error de imagen matricial, debido a que genera mapas de fase bidimensionales directamente.

5.1. Enfoque paramétrico

La evaluación del enfoque paramétrico se divide en dos fases consecutivas: una fase de selección de arquitectura óptima y una fase de validación de rendimiento final frente al estimador tradicional.

5.1.1. Comparativa y selección de arquitecturas MLP

En esta primera etapa, se analiza el desempeño de las siete configuraciones de redes MLP descritas en la metodología. El objetivo es identificar qué variaciones (anchura, profundidad, activaciones o conexiones residuales) favorecen una mejor convergencia en la estimación de los modos de Zernike.

El proceso de selección partió del entrenamiento inicial de las siete configuraciones MLP durante 200 épocas. La Figura 5.1 muestra la evolución del MSE durante este proceso. Se observa que todas las arquitecturas convergen de manera estable y sin indicios de sobreajuste, pues las curvas de validación siguen de cerca a las de entrenamiento. Destaca la rápida convergencia del modelo *wider*, que alcanza el error de validación más

bajo ($5,45 \times 10^{-3}$), superando con margen al resto de configuraciones. Por el contrario, topologías profundas como *deeper* muestran un estancamiento temprano en el conjunto de validación. Esto se puede deber a una profundidad excesiva que resulta injustificada para este tipo de problema, pues los vectores de pendientes son medidas geométricas que ya condensan mucha información física.

Se observan caídas escalonadas en las curvas de validación, especialmente en la red *wider*. Este comportamiento es característico de la estrategia de reducción de la tasa de aprendizaje en mesetas descrita en la Sección 3.4.4, que reduce el *learning rate* al detectar estancamiento, provocando descensos abruptos del error.




Figura 5.1 Curvas de aprendizaje en los conjuntos de entrenamiento y validación para las siete arquitecturas comparadas. Se observa que la red ancha (*wider*) muestra un rendimiento muy superior al resto en el conjunto de validación. La red profunda (*deeper*) muestra un estancamiento temprano debido a la excesiva complejidad introducida. Saltos abruptos en la curva de validación (épocas 70 y 95 de la curva *wider*) son un comportamiento característico de la estrategia de reducción de la tasa de aprendizaje en estancamiento.

La Tabla 5.1 resume la comparativa de las métricas de evaluación promediadas para todos los valores de r_0 , así como el número de parámetros, el tiempo de entrenamiento y la época en la que se alcanzó el error mínimo. Se observa que la red *wider* muestra el mínimo absoluto del MSE en el conjunto de validación, coincidiendo con su última época de entrenamiento. Esto sugiere que el modelo aún se encuentra en fase de convergencia y podría beneficiarse de un entrenamiento más prolongado. Por otro lado, la arquitectura ELU presenta el mínimo error tanto en el RMSE como en el MAE. Cabe destacar que, a excepción de esta variante, el resto de configuraciones empeoran el rendimiento del modelo base en el RMSE.

Red	Params.	Tiempo (s)	Mejor Ép.	MSE Val.	RMSE (rad)	MAE (rad)
Baseline	2.634.264	630	185	$1,2679 \times 10^{-2}$	6,9782	3,0288
<i>Wider</i>	6.844.632	675	200	$5,4493 \times 10^{-3}$	7,3359	2,9837
<i>Deeper</i>	3.952.064	808	200	$1,9285 \times 10^{-2}$	8,0425	3,1791
ELU	2.634.264	624	198	$1,1212 \times 10^{-2}$	6,5975	2,9107
GELU	2.634.264	655	198	$1,2257 \times 10^{-2}$	7,3106	3,0637
Residual	2.201.096	895	193	$1,1905 \times 10^{-2}$	8,3368	3,3186
Fast LR	2.634.264	607	198	$1,4002 \times 10^{-2}$	7,1209	3,0029

Tabla 5.1 Resultados comparativos de las siete arquitecturas MLP evaluadas para la reconstrucción de los modos de Zernike. Las métricas de desempeño final (RMSE y MAE) representan el valor medio calculado abarcando todo el espectro simulado del parámetro de Fried ($r_0 \in [10, 18]$ cm). Por su parte, la columna MSE Val. indica el error mínimo alcanzado en el conjunto de validación durante un máximo de 200 épocas de entrenamiento. Se resalta en negrita el mejor resultado para cada métrica clave.

Resulta llamativo que la red *wider*, pese a alcanzar el menor MSE en el conjunto de validación, presente un RMSE de prueba superior al del modelo base y al de la variante ELU. Esta aparente contradicción tiene su origen en el preprocesamiento descrito en la Sección 4.4.1: la pérdida de validación se evalúa sobre los coeficientes normalizados mediante Z-score, donde cada modo opera en una escala de varianza unitaria. Sin embargo, el RMSE de prueba se calcula tras invertir dicha transformación, recuperando las amplitudes físicas en radianes. Dado que la varianza de los coeficientes de Zernike decae de forma drástica con el orden radial, la desnormalización amplifica de forma desigual el error de cada modo. Los errores cometidos en modos de alto orden, pequeños en el espacio normalizado, se recuperan con pesos muy distintos al volver al espacio físico. La red *wider* minimiza eficazmente la pérdida normalizada pero no generaliza con igual precisión en el espacio físico. La arquitectura ELU, en cambio, presenta un comportamiento más equilibrado entre modos, lo que se traduce en un menor RMSE final en radianes pese a no ser la mejor en validación normalizada.

5.1.2. Entrenamiento extendido y desempeño frente al estimador LS

En base a los resultados expuestos en la sección anterior, se seleccionan los modelos *wider* y ELU para avanzar a la fase de optimización y comparación final. La elección

de cada arquitectura se hace en base a los siguientes criterios:

- **Modelo ELU.** Demostró la mejor capacidad de generalización de toda la batería de pruebas, obteniendo los RMSE y MSE más bajos al evaluar la reconstrucción frente a los conjuntos de datos de prueba no vistos.
- **Modelo *wider*.** Alcanzó el mínimo absoluto en el error de validación. Sin embargo, dado que su mejor desempeño coincidió exactamente con el límite máximo de 200 épocas establecido para la comparativa inicial, es evidente que la red no había convergido por completo. Un horizonte de entrenamiento más amplio es necesario para extraer todo su potencial predictivo.

A continuación, estas arquitecturas se someten a un entrenamiento extendido de 500 épocas para asegurar la estabilización total de los pesos y minimizar el error residual.

La Figura 5.2 muestra las curvas de aprendizaje en los conjuntos de entrenamiento y validación de ambas arquitecturas. La parada temprana detuvo el entrenamiento en la época 190 para el modelo *wider* y en la 240 para el modelo ELU. Esto no supone ninguna contradicción con lo anterior ya que el entrenamiento no es completamente determinista, y en esta ejecución el modelo *wider* alcanzó su mínimo de validación antes, sin mejora posterior durante el número de épocas de paciencia establecido. El modelo ELU, en cambio, continuó reduciendo su error de validación de forma más gradual hasta la época 240. Se observa, además, que ambos modelos aprenden la mayoría de la información antes de las 150 primeras épocas, con un aplanamiento marcado en las épocas posteriores.

La Tabla 5.2 muestra los valores de RMSE y MAE para ambos modelos, así como su comparación con el método de mínimos cuadrados. Se observa que ambos modelos mejoran las predicciones de este último. En particular, la red *wider* logró una reducción media del error de fase del 65,70 %, mientras que la arquitectura basada en la activación ELU alcanzó una mejora promedio del 67,74 %. Esto demuestra que las arquitecturas paramétricas propuestas superan ampliamente el límite de rendimiento del estimador tradicional.




Figura 5.2 Evolución del MSE durante el entrenamiento extendido de las arquitecturas neuronales seleccionadas. Se muestran las curvas para el conjunto de entrenamiento y el conjunto de validación. La convergencia asintótica de las curvas de entrenamiento y validación hacia valores similares confirma la ausencia de sobreajuste significativo en ambos modelos. El entrenamiento finalizó automáticamente en la época 190 para el modelo *wider* y en la 240 para el modelo ELU debido a la parada temprana.

5.2. Enfoque espacial

En esta sección se discute el entrenamiento de la red FCN y se compara cuantitativamente con el método LS.

5.2.1. Entrenamiento de la red FCN

Como se discutió en la metodología, la red FCN se entrenó con un límite máximo de 200 épocas. Sin embargo, la parada temprana detuvo el proceso en la época 147, resultando en un tiempo total de entrenamiento de 256 horas. Este tiempo supone un factor de aproximadamente 1000 respecto a los 15 minutos requeridos por las arquitecturas MLP descritas en la sección anterior.

La Figura 5.3 muestra la evolución del MSE normalizado durante el entrenamiento y la validación. Se observa una alta variabilidad del error de validación en las primeras épocas, junto con un descenso rápido del error de entrenamiento. Posteriormente, ambas curvas presentan una disminución más gradual hasta alcanzar una región de estabilización. Este comportamiento es consistente con una fase inicial de optimización inestable,

r_0 (cm)	Red <i>Wider</i>		Red ELU		Mínimos Cuadrados	
	RMSE	MAE	RMSE	MAE	RMSE	MAE
10	1,6038	1,0757	1,4871	1,0383	4,4738	3,5594
11	1,4686	0,9878	1,3651	0,9533	4,1448	3,2980
12	1,3538	0,9146	1,2628	0,8823	3,8663	3,0767
13	1,2556	0,8518	1,1762	0,8219	3,6269	2,8862
14	1,1694	0,7956	1,1012	0,7694	3,4184	2,7203
15	1,0954	0,7465	1,0346	0,7230	3,2349	2,5742
16	1,0295	0,7019	0,9768	0,6825	3,0717	2,4442
17	0,9714	0,6620	0,9252	0,6467	2,9259	2,3280
18	0,9208	0,6270	0,8799	0,6149	2,7944	2,2233

Tabla 5.2 Comparativa del error espacial, medido en radianes, en la reconstrucción del frente de onda para los diferentes regímenes de turbulencia simulados (r_0). Se observa cómo las arquitecturas neuronales (*wider* y ELU) superan consistentemente al estimador clásico de mínimos cuadrados. El modelo ELU presenta el mínimo RMSE en todos los escenarios evaluados (resaltado en negrita).

en la que los parámetros aún se ajustan de forma significativa, seguida de una etapa en la que las actualizaciones producen mejoras cada vez menores. Hacia las últimas épocas, ambas curvas se estabilizan alrededor de valores próximos, sin observarse una divergencia creciente entre entrenamiento y validación.

5.2.2. Comparativa con el método de LS

Los resultados de la Tabla 5.3 muestran que la red FCN supera de forma sistemática al método de mínimos cuadrados para todos los valores de r_0 analizados. En todos los casos, el error RMS medio obtenido por la FCN es inferior al correspondiente al estimador LS, lo que indica una mejora consistente de la reconstrucción espacial del frente de onda.

La diferencia entre ambos métodos se mantiene en todo el intervalo de turbulencia considerado. Para $r_0 = 10$ cm, la FCN obtiene un RMS medio de 3,6594 rad, frente a 4,3157 rad para LS. A medida que aumenta r_0 , ambos métodos reducen su error, como era esperable al disminuir la severidad de la turbulencia. Además, el cociente LS/FCN pasa de 1,1793 para $r_0 = 10$ cm a 1,2127 para $r_0 = 18$ cm.




Figura 5.3 Curva de entrenamiento de la red FCN. El error de validación presenta una alta variabilidad en las primeras épocas, seguida de una estabilización posterior. Ambas curvas se estabilizan a partir de la época 100. La parada temprana detiene el entrenamiento en la época 147.

En términos relativos, estos valores implican que el método LS presenta errores aproximadamente entre un 17,9% y un 21,3% mayores que los de la FCN, dependiendo del régimen de turbulencia. De forma equivalente, la FCN reduce el error respecto a LS entre aproximadamente un 15,2% y un 17,5%. La mejora media en el intervalo completo es cercana al 16,1%.

También se observa que la desviación típica del error es menor para la FCN en todos los casos, lo que indica una reconstrucción más estable entre realizaciones. Esta reducción de la dispersión tiene implicaciones directas en sistemas de óptica adaptativa reales, donde la variabilidad frame a frame de las correcciones aplicadas al espejo deformable puede comprometer la estabilidad del bucle de control.

5.3. Comparación entre enfoques

Los dos enfoques abordan la reconstrucción del frente de onda desde representaciones distintas. El paramétrico (MLP) estima coeficientes de Zernike a partir de las pendientes, restringiendo la salida a una base modal de baja dimensionalidad. Esto simplifica

r_0 (cm)	FCN		Mínimos Cuadrados		Ratio LS/FCN
	$\overline{\text{RMS}}$	σ_{RMS}	$\overline{\text{RMS}}$	σ_{RMS}	
10	3,6594	1,0788	4,3157	1,3537	1,1793
11	3,3895	0,9988	4,0000	1,2492	1,1801
12	3,1608	0,9316	3,7356	1,1544	1,1818
13	2,9642	0,8741	3,5137	1,0707	1,1854
14	2,7929	0,8246	3,3212	1,0021	1,1891
15	2,6422	0,7809	3,1563	0,9398	1,1946
16	2,5082	0,7424	3,0057	0,8797	1,1983
17	2,3885	0,7079	2,8799	0,8301	1,2057
18	2,2806	0,6770	2,7655	0,7882	1,2127

Tabla 5.3 Tabla comparativa de resultados entre la red FCN y el método de LS. La red FCN logra superar al estimador clásico de LS para todos los valores de r_0 , presentando un error un 16 % menor en promedio. La arquitectura convolucional muestra además una desviación típica menor, garantizando una mayor estabilidad en sistemas de OA reales. Todos los valores están medidos en radianes.

el aprendizaje, acelera la convergencia y mantiene una interpretación física directa de las aberraciones. Por otro lado, el enfoque espacial (FCN) predice el mapa de fase bidimensional completo a partir de la imagen focal. Al no imponer una base modal finita, posee mayor flexibilidad para capturar estructuras locales complejas, pero exige una optimización más difícil, mayor volumen de datos y un tiempo de entrenamiento considerablemente superior.

Empíricamente, las arquitecturas MLP son más eficientes computacionalmente. La red convolucional, aunque converge sin sobreajuste, presenta validaciones más fluctuantes debido a los mayores grados de libertad que exige la regresión espacial continua. Por tanto, el enfoque paramétrico resulta idóneo para aplicaciones que exijan rapidez y operación en tiempo real, mientras que la FCN es preferible en escenarios donde la reconstrucción detallada del mapa de fase sea prioritaria y el coste computacional no suponga una limitación.

6. Conclusiones y Trabajo Futuro

En este capítulo se sintetizan los hallazgos principales del estudio, evaluando el rendimiento de los modelos de aprendizaje profundo frente al estimador clásico de mínimos cuadrados. Además, se establecen las líneas de trabajo futuras.

6.1. Conclusiones

- **Superioridad frente a métodos clásicos.** Ambos enfoques de aprendizaje profundo superan al estimador clásico de LS en todos los regímenes de turbulencia evaluados.
- **Rendimiento del enfoque paramétrico.** La arquitectura con activación ELU obtiene el menor RMSE final y la mayor capacidad de generalización, logrando una reducción media del error del 67,74% frente a LS. La red *wider*, pese a alcanzar el menor MSE de validación normalizado, no traslada esa ventaja al espacio físico debido a la desigual distribución de varianza entre modos de Zernike.
- **Rendimiento del enfoque espacial.** La arquitectura FCN reduce el error RMS medio espacial entre un 15,2% y un 17,5% respecto a LS. Esta ventaja relativa se incrementa en condiciones de menor turbulencia. Adicionalmente, la red presenta una menor dispersión del error residual, garantizando una reconstrucción de fase más estable.
- **Comparación entre métodos.** El enfoque paramétrico es computacionalmente más eficiente y ofrece resultados interpretables en términos de aberraciones ópticas. El enfoque espacial es más flexible pero requiere un coste de entrenamiento considerablemente mayor.

6.2. Líneas de trabajo futuro

Las líneas de trabajo futuro se agrupan en dos bloques: análisis de la capacidad de generalización de los modelos empleados (1, 2 y 3) e incorporación de nuevas arquitecturas (4 y 5):

1. **Evaluar el rendimiento de los modelos usando datos de telescopios reales.** Validar la respuesta de las redes frente a fuentes de error ausentes en la simulación, como el ruido de fotones sobre los sensores CCD o problemas de calibración.
2. **Aplicación a sistemas reales de OA solar.** Emplear el enfoque espacial como reconstructor en sistemas de OA solar en operación. Dada la alta carga computacional del cálculo de correlaciones cruzadas en los Shack-Hartmann solares, una red neuronal podría inferir la fase de forma más eficiente a partir de fuentes extendidas de bajo contraste.
3. **Aumentar el espacio de simulación atmosférica.** Ampliar el rango de condiciones atmosféricas simuladas, incorporando turbulencias más severas y valores de r_0 no vistos durante el entrenamiento. Además, se pueden introducir variaciones en el perfil vertical de turbulencia $C_n^2(h)$ y en la escala externa de von Kármán L_0 , permitiendo caracterizar los límites de generalización teóricos de cada modelo.
4. **Desarrollo de modelos híbridos.** Explorar arquitecturas que integren la alta eficiencia computacional del enfoque paramétrico con la flexibilidad del espacial. Esto permitiría emplear la estimación modal rápida de una MLP como etapa de inicialización para guiar la reconstrucción de alta resolución de una FCN, optimizando el compromiso entre precisión y velocidad de procesamiento.
5. **Exploración de arquitecturas avanzadas.** Evaluar el uso de redes de tipo U-Net para optimizar la regresión en el mapa de fase, o la incorporación de bloques residuales (ResNet) que faciliten el entrenamiento de topologías más profundas.

Bibliografía

- [1] Robert K. Tyson. *Introduction to Adaptive Optics*. Bellingham, WA: SPIE Press, 1991.
- [2] Isaac Newton. *Opticks: Or, A Treatise of the Reflexions, Refractions, Inflexions and Colours of Light*. London: Samuel Smith y Benjamin Walford, 1704.
- [3] Stephen B. Pope. *Turbulent Flows*. Cambridge University Press, 2000.
- [4] John C. Wyngaard. *Turbulence in the Atmosphere*. Cambridge University Press, 2010.
- [5] Valeriano I. Tatarskii. *Wave Propagation in a Turbulent Medium*. Translated from the Russian by R. A. Silverman. New York: McGraw-Hill, 1961.
- [6] Andrey N. Kolmogorov. «The local structure of turbulence in incompressible viscous fluid for very large Reynolds numbers». En: *Turbulence: Classic Papers on Statistical Theory*. Ed. por S. K. Friedlander y L. Topper. Translated from the original 1941 Russian article. New York: Interscience Publishers, 1961, págs. 151-155.
- [7] Robert K. Tyson. *Principles of Adaptive Optics*. 5th. Boca Raton: CRC Press, 2022. ISBN: 978-0-367-61694-3.
- [8] L. C. Andrews y R. L. Phillips. *Laser Beam Propagation through Random Media*. 2nd. Bellingham, WA: SPIE Press, 2005.
- [9] Stanley Corrsin. «On the spectrum of isotropic temperature fluctuations in an isotropic turbulence». En: *Journal of Applied Physics* 22.4 (1951), págs. 469-473.
- [10] David L. Fried. «Statistics of a Geometric Representation of Wavefront Distortion». En: *Journal of the Optical Society of America* 55.11 (1965), págs. 1427-1435.

- [11] John W. Hardy. *Adaptive Optics for Astronomical Telescopes*. Oxford Series in Optical and Imaging Sciences. New York: Oxford University Press, 1998. ISBN: 9780195090192.
- [12] Craig F. Bohren y Donald R. Huffman. *Absorption and Scattering of Light by Small Particles*. John Wiley & Sons, 1983.
- [13] R. Q. Fugate et al. «Measurement of atmospheric isoplanatism using laser Rayleigh scattering». En: *Nature* 353.6340 (1991), págs. 144-146.
- [14] W. Happer et al. «Atmospheric-turbulence compensation by resonant optical backscattering from the sodium layer in the upper atmosphere». En: *Journal of the Optical Society of America A* 11.1 (1994), págs. 263-276.
- [15] Eugene Hecht. *Optics*. 5th. Pearson, 2017.
- [16] Johannes Franz Hartmann. «Bemerkungen über den Bau und die Justirung von Spektrographen». En: *Zeitschrift für Instrumentenkunde* 20 (1900), págs. 47-58.
- [17] Roland V. Shack y Ben C. Platt. «Production and use of a lenticular Hartmann screen». En: *Journal of the Optical Society of America* 61.5 (1971), pág. 656.
- [18] Maria Vinas-Pena. «Polychromatic Adaptive Optics to evaluate the impact of manipulated optics on vision». Tesis doct. Universidad Complutense de Madrid, dic. de 2015. DOI: [10.13140/RG.2.1.2540.0402](https://doi.org/10.13140/RG.2.1.2540.0402).
- [19] Francisco García Riesgo. «Desarrollo de un sistema de reconstrucción tomográfica para óptica adaptativa solar mediante redes neuronales artificiales». Tesis Doctoral. Universidad de Oviedo, 2023.
- [20] Byoungyoul Park. «Development of a Low Voltage and Large Stroke MEMS-based Lorentz Force Continuous Deformable Polymer Mirror System». Tesis doct. Sep. de 2018. DOI: [10.13140/RG.2.2.18013.46562](https://doi.org/10.13140/RG.2.2.18013.46562).
- [21] W. H. Press et al. *Numerical Recipes*. Cambridge: Cambridge University Press, 1989.
- [22] R. Gilmozzi y J. Spyromilio. «The European Extremely Large Telescope (E-ELT)». En: *The Messenger* 127 (2007), págs. 11-17.
- [23] Suarez Gómez Sergio Luis. «Desarrollo de un sistema de reconstrucción tomográfica para óptica adaptativa solar mediante redes neuronales artificiales». Tesis Doctoral. Universidad de Oviedo, 2020.

- [24] European Southern Observatory. *AOModes*. Última actualización: 30 de mayo de 2013. Accedido: 12 de mayo de 2026. 2013. URL: https://www.eso.org/sci/facilities/develop/ao/ao_modes/.html.
- [25] Thomas R Rimmele y Jose Marino. «Solar adaptive optics». En: *Living Reviews in Solar Physics* 8.1 (2011).
- [26] Alastair G Basden. «Monte Carlo modelling of multiconjugate adaptive optics performance on the European Extremely Large Telescope». En: *Monthly Notices of the Royal Astronomical Society* 453.3 (2015), págs. 3035-3042. DOI: [10.1093/mnras/stv1875](https://doi.org/10.1093/mnras/stv1875).
- [27] Alastair Basden et al. «The Durham Adaptive Optics Simulation Platform (DASP): Current status». En: *SoftwareX* 7 (2018), págs. 63-69. DOI: [10.1016/j.softx.2018.02.001](https://doi.org/10.1016/j.softx.2018.02.001).
- [28] Snehith Vaddi. *The Concept of Artificial Neurons: Perceptrons in Neural Networks*. Accedido el 11 de febrero de 2026. Towards Data Science. 2020. URL: <https://towardsdatascience.com/the-concept-of-artificial-neurons-perceptrons-in-neural-networks-fab22249cbfc/> (visitado 11-02-2026).
- [29] Kurt Hornik, Maxwell Stinchcombe y Halbert White. «Multilayer feedforward networks are universal approximators». En: *Neural Networks* 2.5 (1989), págs. 359-366.
- [30] Simon J. D. Prince. *Understanding Deep Learning*. Cambridge, MA: MIT Press, 2023. ISBN: 9780262048644. URL: <https://udlbook.com/>.
- [31] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. Cambridge, MA: MIT Press, 2016. URL: <http://www.deeplearningbook.org>.
- [32] Léon Bottou. «Large-scale machine learning with stochastic gradient descent». En: *Proceedings of COMPSTAT'2010*. Springer, 2010, págs. 177-186.
- [33] Diederik P Kingma y Jimmy Ba. «Adam: A method for stochastic optimization». En: *arXiv preprint arXiv:1412.6980* (2014).
- [34] François Chollet. *Deep Learning with Python*. 2nd. Shelter Island, NY: Manning Publications, 2021. ISBN: 9781617296864.
- [35] Lei Zhang et al. «Automatic Pavement Crack Detection Using Deep Convolutional Neural Networks». En: *IEEE Transactions on Intelligent Transportation Systems* (2016).

- [36] Jonathan Long, Evan Shelhamer y Trevor Darrell. «Fully Convolutional Networks for Semantic Segmentation». En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2015), págs. 3431-3440. DOI: [10.1109/CVPR.2015.7298965](https://doi.org/10.1109/CVPR.2015.7298965). arXiv: [1411.4038](https://arxiv.org/abs/1411.4038) [cs.CV].
- [37] Sergey Ioffe y Christian Szegedy. «Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift». En: *International Conference on Machine Learning (ICML)*. PMLR. 2015, págs. 448-456.
- [38] Djork-Arné Clevert, Thomas Unterthiner y Sepp Hochreiter. «Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)». En: *International Conference on Learning Representations (ICLR)*. 2016.
- [39] Dan Hendrycks y Kevin Gimpel. «Gaussian error linear units (GELUs)». En: *arXiv preprint arXiv:1606.08415* (2016).
- [40] Kaiming He et al. «Deep residual learning for image recognition». En: *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*. 2016, págs. 770-778.
- [41] R. J. Noll. «Zernike polynomials and atmospheric turbulence». En: *Journal of the Optical Society of America* 66.3 (1976), págs. 207-211.